

코딩동아리 이론 세션

정형 데이터 vs 비정형 데이터

데이터는 모두 같은 모양일까 ?

발표 김택동



세상의 데이터 , 대부분은 표가 아니다

80%

정형
~20%

비정형 ~80%

전 세계 데이터 중
비정형 데이터가 차지하는 비중 (추정)

텍스트 · 이미지 · 음성 · 영상

* IDC·Gartner 등 업계에서 흔히 인용되는 추정치로 , 출처에 따라 80~90% 로 제시됨

정형 데이터 (Structured)

미리 정해진 틀 (스키마) 에 맞춰 행과 열로 저장된 데이터

- 각 열의 이름과 자료형이 고정
- SQL 로 바로 검색 · 집계 가능
- 예) 엑셀 시트 , MySQL·PostgreSQL,
결제 내역 , 성적표

주문 ID	메뉴	가격	주문일
1001	치킨	20,000	09-28
1002	피자	18,500	09-29
1003	떡볶이	14,000	09-30

SELECT AVG(가격) FROM 주문 ; → 17,500

비정형 데이터 (Unstructured)

정해진 구조 없이 저장된 데이터 — 사람에게겐 풍부하지만 , 컴퓨터는 바로 계산할 수 없다



텍스트

리뷰 , 이메일 , SNS 글



이미지

사진 , 의료 영상



음성

통화 녹음 , 음성 메모



영상

유튜브 , CCTV

분석하려면 → 자연어처리 (NLP) · 컴퓨터 비전 · 음성 인식 · 딥러닝

그 사이 : 반정형 데이터 (Semi-structured)

```
[  
  { "user": "택동",  
    "rating": 5,  
    "photos": ["a.jpg"] },  
  { "user": "민지",  
    "rating": 3,  
    "comment": "배달 늦음 " }  
]
```

키 · 태그로 구조를 스스로 설명하지만,
형식이 딱 고정되지는 않은 데이터

- JSON — API 응답
- XML, HTML
- 서버 로그 파일

리뷰마다 필드가 달라도 OK!
개발자가 가장 자주 만나는 형태

한눈에 비교하기

구분	정형 데이터	비정형 데이터
구조	행 · 열 , 스키마 고정	고정된 구조 없음
저장	관계형 DB (RDBMS)	NoSQL, 데이터 레이크 , 파일
분석 방법	SQL, 통계 , 머신러닝	NLP, 컴퓨터 비전 , 딥러닝
분석 난이도	쉬움 — 바로 계산	어려움 — 전처리 필요
예시	결제 내역 , 성적표	리뷰 , 사진 , 음성

실제로는 함께 쓴다 — 배달앱 리뷰

정형

별점 4.5 · 메뉴 · 주문 시간

비정형

"양 많고 맛있는데 배달이 좀 늦었어요" + 음식 사진

비정형 → 정형 변환

감성 분석

→ 긍정 점수 0.72

키워드 추출

→ [양, 맛, 배달지연]



별점은 높지만
'배달 지연'
불만이 늘고 있다

인사이트

정리

- 1 정형 데이터는 표 형태 — 바로 계산할 수 있다
- 2 비정형 데이터는 세상 데이터의 대부분 — 전처리와 AI 가 필요하다
- 3 핵심은 비정형을 정형으로 바꿔 함께 분석하는 것

감사합니다 · Q&A