



비정형데이터/정형데이터

🕒 작성일시	2026년 9월 28일 오후 5:41
☑ O/X	☐

데이터

데이터 종류

정형 데이터 (Structured Data)

특징

비정형 데이터 (Unstructured Data)

특징

데이터 형태별 저장 및 관리 기술

RDBMS (관계형 데이터베이스 관리시스템)

NoSQL (비관계형 데이터베이스)

데이터 레이크 (Data Lake) 및 오브젝트 스토리지

비정형 데이터의 정형화 및 전처리

텍스트 전처리

이미지/음성 전처리

벡터 임베딩

비정형 데이터 분석 핵심 기술

자연어 처리 (NLP - Natural Language Processing)

컴퓨터 비전 (Computer Vision)

멀티모달 AI (Multimodal AI)

데이터



데이터

- 현실 세계에서 단순히 관찰하거나 측정하여 수집한 사실이나 값
- 의미가 부여되지 않은 객관적 사실
- 가공하기 전 순수한 수치나 기호 자체

EX) 회원의 가입 내역, 대리점의 매출내역, 회원의 시스템 로그인 시간 등

데이터 종류

구분	정형 데이터 (Structured Data)	비정형 데이터 (Unstructured Data)
정의	정해진 규칙과 형식(행과 열)에 맞춰 저장된 데이터	일정한 규칙이나 형태 없이 저장된 데이터
비율	전체 생성 데이터의 약 20%	전체 생성 데이터의 약 80% 이상
저장 위치	관계형 데이터베이스(RDBMS), 데이터 웨어하우스	데이터 레이크(Data Lake), NoSQL 저장소
분석 방법	SQL 등의 언어로 쉽고 빠르게 검색 및 연산 가능	텍스트 마이닝, 컴퓨터 비전, 자연어 처리(NLP) 등 AI 기술 필요
대표적인 예	엑셀 스프레드시트, 은행 거래 내역, 고객 주소록	이미지, 유튜브 동영상, 오디오, SNS 게시물, 이메일 본문

정형 데이터 (Structured Data)

미리 정해진 형식과 구조(스키마)에 따라 체계적으로 저장되는 데이터

특징

- 높은 안정성, 유연하지 못한 구조
- 금융, 제조 등 대부분 기업의 업무용 데이터베이스



장점: 데이터의 구조가 명확하여 컴퓨터가 읽기 쉬움⇒검색, 정렬, 통계 분석, 수정에 용이

비정형 데이터 (Unstructured Data)

형태와 구조가 정해져 있지 않은 자유로운 형태의 데이터, 가장 큰 비중을 차지

특징

파일의 크기가 크고 형태가 다양해서 전통적인 행과 열 형태의 데이터베이스에는 바로 저장할 수 없음

데이터 형태별 저장 및 관리 기술

RDBMS (관계형 데이터베이스 관리시스템)

- 적용: 정형 데이터
- 특징: Oracle, MySQL, PostgreSQL 등 정형 데이터의 무결성과 트랜잭션(ACID) 처리에 최적화되어 있다.

NoSQL (비관계형 데이터베이스)

- 적용: 반정형 데이터 및 일부 비정형 데이터
- 특징: MongoDB, Redis, Cassandra 등 고정된 스키마 없이 Document, Key-Value 형태로 저장하며, 대용량 데이터의 수평적 확장에 유리하다

데이터 레이크 (Data Lake) 및 오브젝트 스토리지

- 적용: 정형, 반정형, 비정형 데이터 전체
- 특징: AWS S3, Google Cloud Storage, Hadoop HDFS 등 가공되지 않은 대규모 원천 데이터를 저렴한 비용으로 수집해 두고, 분석이 필요한 시점에 구조화하여 활용

비정형 데이터의 정형화 및 전처리

비정형 데이터를 머신러닝이나 통계 모델에서 활용하려면 수치 형태나 정형화된 구조로 변환해야 함

텍스트 전처리

- 정제 및 정규화: 소문자 변환, 특수문자 및 노이즈 제거, 불용어 제거
- 토큰화: 문장을 단어, 형태소, 서브워드 단위로 분할
- 표제어 추출: 단어의 기본 원형을 복원하여 데이터 차원 축소

이미지/음성 전처리

- 이미지: 크기 정규화, 채널 변환, 노이즈 제거, 데이터 증대
- 음성: 음파를 주파수 영역으로 변환하여 스펙트로그램 형태의 2차원 시각적 데이터로 변환

벡터 임베딩

- 고차원의 비정형 데이터(단어, 문장, 이미지)를 의미적 관계를 유지한 채 머신러닝이 연산할 수 있는 연속된 수치 벡터로 변환
- 변환된 벡터 간의 거리를 계산하여 비정형 데이터 간의 의미적 유사성을 파악

비정형 데이터 분석 핵심 기술

자연어 처리 (NLP - Natural Language Processing)

- 주요 분야: 텍스트 분류, 문서 요약, 기계 번역, 정보 추출, 질의 응답
- 대표 모델: Transformer 아키텍처 기반의 대규모 언어 모델 (LLM, GPT, BERT 등)

컴퓨터 비전 (Computer Vision)

- 주요 분야: 이미지 분류, 객체 탐지, 영역 분할, OCR(광학 문자 인식)
- 대표 모델: CNN(Convolutional Neural Network), VisionTransformer(ViT)

멀티모달 AI (Multimodal AI)

텍스트, 이미지, 음성 등 서로 다른 형태의 비정형 데이터를 하나의 모델 내에서 통합적으로 이해하고 연계하는 기술