

2주차 이론

정형데이터: 미리 정의된 스키마에 따라 행(레코드)과 열(속성)로 고정된 형식에 저장되는 데이터다. 각 열은 정수, 문자열, 날짜 같은 데이터 타입이 정해져 있어 곧바로 검색·집계·계산할 수 있다.

주요 특징

- **고정된 구조:** 모든 레코드가 같은 필드 구성을 가진다.
- **높은 연산 가능성:** SQL로 필터링, 정렬, 조인, 집계 등 즉시 가능하다.
- **무결성 보장:** 기본키·외래키·제약 조건으로 중복과 오류를 막는다.
- **낮은 유연성:** 새 속성을 추가하려면 스키마를 변경해야 하며, 대규모 테이블에서는 비용이 크다.

저장 방식

대표 저장소는 관계형 데이터베이스(RDBMS)로, Oracle, MySQL, PostgreSQL 등이 있다. 트랜잭션의 원자성·일관성·고립성·지속성(ACID)을 보장해 금융 거래처럼 정확성이 중요한 업무에 쓰인다. 분석용으로는 여러 시스템의 정형 데이터를 모은 데이터 웨어하우스가 쓰인다.

예시

- 은행 계좌 거래 내역(일시, 금액, 계좌번호)
- ERP·CRM의 고객·주문·재고 정보
- 학사 관리 시스템의 성적표
- 스프레드시트 형태의 매출 집계표

비정형 데이터: 미리 정의된 데이터 모델이나 스키마가 없는 데이터다. 사람에게 의미는 분명하지만, 컴퓨터가 그 의미를 이해하려면 별도의 해석·추출 과정이 필요하다.

주요 특징

- **형식의 다양성:** 텍스트, 이미지, 음성, 영상 등 형태가 제각각이다.
- **풍부한 맥락 정보:** 감정, 뉘앙스, 시각적 패턴처럼 숫자로 담기 어려운 정보를 포함한다.
- **낮은 연산 가능성:** 그대로는 집계·검색이 어렵고, 자연어 처리나 컴퓨터 비전으로 특징을 먼저 뽑아야 한다.
- **대용량:** 파일 하나의 크기가 크고 생성 속도도 빨라 저장·전송 비용이 높다.

저장 방식

원본 파일을 그대로 보관하는 방식이 기본이다. 분산 파일 시스템(HDFS), 객체 스토리지(Amazon S3 등), 데이터 레이크가 대표적이다. 최근에는 비정형 데이터를 임베딩 벡터로 변환해 의미 기반으로 검색하는 벡터 데이터베이스도 널리 쓰인다.

예시

- 이메일 본문, 보고서, 계약서 등 문서
- SNS 게시글과 상품 리뷰
- 사진, 의료 영상(X-ray, MRI), CCTV 영상
- 콜센터 통화 녹음, 회의 음성

반정형 데이터: 고정된 테이블 스키마는 없지만, 태그나 키-값 쌍으로 데이터 스스로 구조를 설명하는 형태다. 이를 '자기 기술적(self-describing)' 구조라고 한다.

주요 특징

- 자기 기술적 구조: 태그나 키-값 쌍으로 데이터 스스로 구조를 설명한다.
- 유연한 스키마: 레코드마다 필드 구성이 달라도 되며, 필드 추가가 쉽다.
- 계층·중첩 표현: 데이터 안에 데이터를 넣는 트리 형태의 복잡한 정보를 담을 수 있다.
- 중간 수준의 처리 난이도: 정형 데이터보다 유연하고, 비정형 데이터보다 기계가 해석하기 쉽다.

저장 방식

문서형 NoSQL 데이터베이스(MongoDB 등)에 저장하는 방식이 대표적이다. 키-값 저장소(Redis, DynamoDB)나 데이터 레이크에 원본 파일로 보관하기도 한다. 최근에는 관계형 데이터베이스(PostgreSQL 등)도 JSON 타입을 지원해 정형 데이터와 함께 저장하는 경우가 많다.

예시

- JSON, XML, YAML, HTML 문서
- 웹 API 응답 데이터
- 웹 서버·애플리케이션 로그
- IoT 센서 메시지, 이메일(헤더는 구조화, 본문은 자유 형식)