

정형 데이터와 비정형 데이터

1. 데이터의 정의와 분류 기준

데이터는 형태와 구조화 정도에 따라 크게 세 가지로 나뉜다.

- 정형 데이터(Structured Data): 미리 정해진 스키마(행과 열, 데이터 타입)에 맞춰 저장되는 데이터
 - 비정형 데이터(Unstructured Data): 고정된 구조가 없는 데이터
 - 반정형 데이터(Semi-Structured Data): 정형 데이터와 비정형 데이터의 중간 형태
- 이 분류 기준의 핵심은 '스키마가 미리 정의되어 있는가', '그 스키마가 고정적인가'이다. 정형 데이터는 스키마가 데이터보다 먼저 존재하고 (schema-on-write), 비정형 데이터는 스키마 없이 데이터 자체만 존재하며 필요할 때 의미를 부여한다. (Schema-on-read). 이 차이가 이후 저장, 검색, 처리 방식 전반을 결정 짓기 때문에 정형/비정형을 나누는 가장 근본적인 기준이 된다.

2. 정형 데이터란?

정형 데이터는 관계형 데이터베이스(RDBMS)의 테이블처럼 행(row)과 열(column)로 이루어진 데이터를 말한다. 각 열은 정해진 데이터 타입(정수, 문자열, 날짜 등)을 가지고, 각 행은 하나의 개체(레코드)를 나타낸다.

<구조적 특징>

- 고정된 스키마: 열의 이름과 타입이 미리 정의되어 있어야 데이터를 넣을 수 있다.
- 관계형 모델: 여러 테이블이 키(key)를 통해 서로 연결되어 있는 경우가 많다. (예: 고객 테이블과 주문 테이블이 고객 ID)로 연결)
- 질의 언어(SQL)로 검색 가능: 구조가 명확하기 때문에 조건에 맞는 데이터를 정확하게 필터링·집계할 수 있다.

대표적인 예시로는 엑셀 스프레드시트, 관계형 DB(MySQL, PostgreSQL), CSV 파일 등이 있다. 정형 데이터의 장점은 처리와 분석이 빠르고 정확하다는 것이지만, 반대로 미리 정의된 스키마에 맞지 않는 정보(예: 자유 서술형 텍스트)는 담기 어렵다는 한계가 있다.

3. 비정형 데이터란?

비정형 데이터는 고정된 행/열 구조 없이 존재하는 데이터를 말한다. 텍스트, 이미지, 음성, 영상 등이 대표적이며, 전체 데이터 중 실제로는 비정형 데이터가 차지하는 비중이 훨씬 크다고 알려져 있다.

<주요 유형>

- 텍스트 데이터: 뉴스 기사, SNS 게시글, 리뷰 등
- 이미지 데이터: 사진, 스캔, 문서 등
- 음성/오디오 데이터: 통화 녹음, 음성 명령 등
- 영상 데이터: CCTV 영상, 유튜브 영상 등

비정형 데이터의 공통된 특징은 '사람이 보기엔 의미가 명확하지만, 컴퓨터가 곧바로 정형화된 방식으로 처리하기 어렵다'는 점이다. 그래서 분석하려면 별도의 전처리나 모델(자연어처리, 컴퓨터 비전 등)을 거쳐 의미 있는 정보를 추출해야 한다.

4. 정형 vs 비정형

기준	정형 데이터	비정형 데이터
스키마	사전에 고정 (shcema-on-write)	없음 또는 사용 시점에 부여 (schema-on-read)
저장 방식	관계형 DB, 테이블 형태	파일 시스템, 객체 스토리지, NoSQL 등
검색/질의	SQL로 정확한 조건 검색 가능	키워드 검색이나 유사도 검색에 의존
처리 난이도	상대적으로 낮음 (구조가 명확)	상대적으로 높음 (의미 추출 필요)
예시	회원 DB, 매출 테이블	리뷰 텍스트, 사진, 녹취록

정형 데이터는 이미 컴퓨터가 이해할 수 있는 형태로 정리돼 있고,

비정형 데이터는 사람에게는 자연스럽게만 컴퓨터에게는 별도의 해석 과정이 필요하다.

이 차이 때문에 비정형 데이터를 다루려면

전처리 단계에서 훨씬 더 많은 작업(토큰화, 임베딩, 특징 추출 등)이 들어간다.

5. 반정형 데이터의 위치 - 둘의 중간 지점

반정형 데이터는 완전히 자유로운 형태는 아니지만, 관계형 DB처럼 고정된 테이블 스키마를 따르지도 않는 데이터다. 대표적으로 JSON, XML, 로그 파일 등이 있다.

<특징>

- 태그나 키-값 쌍으로 구조를 표현하지만, 필드가 유동적으로 추가/생략될 수 있다.
- 계층적 구조(중첩된 객체나 배열)를 가질 수 있어 관계형 테이블보다 유연하다.
- 정형 데이터만큼 엄격하진 않지만, 비정형 데이터보다는 파싱과 처리가 훨씬 쉽다.

실제 현업이나 프로젝트에서 다루는 데이터가 순수한 정형/비정형으로 딱 나뉘기보다 반정형인 경우가 많다. 예를 들어 API 응답, 웹 크롤링 결과, 설정 파일 등이 대부분 JSON/XML 형태의 반정형 데이터다.

6. 각 데이터 유형별 수집 방법

- 정형 데이터 수집: 이미 구축된 데이터베이스에서 SQL 쿼리로 조회하거나, 공공데이터포털 같은 곳에서 CSV/엑셀 형태로 다운로드하는 방식이 일반적이다. API를 통해 정형화된 응답(JSON이지만 구조가 고정적인 경우)을 받아오는 것도 포함된다.
- 비정형 데이터 수집: 웹 크롤링/스크래핑을 통해 텍스트나 이미지를 직접 수집하거나, Kaggle·Hugging Face 같은 곳에서 이미 구축된 오픈 데이터셋을 활용하는 방식이 많다. 센서 로그나 사용자 행동 로그처럼 시스템에서 자동 생성되는 데이터도 비정형/반정형에 해당하는 경우가 많다.

7. AI 엔지니어링 관점에서의 의미 - 임베딩/벡터화 필요성

정형 데이터는 SQL 질의로 바로 검색·집계가 가능하지만, 비정형 데이터(특히 텍스트)는 "의미가 비슷한 내용을 찾는" 방식의 검색이 필요하다. 이를 위해 텍스트를 임베딩(embedding)이라는 고정 차원의 숫자 벡터로 변환하고, 벡터 간 유사도(코사인 유사도 등)를 계산해서 의미적으로 가까운 데이터를 찾는다.

이 과정이 바로 RAG(Retrieval-Augmented Generation)의 핵심 구조와 맞닿아 있다:

- 비정형 텍스트 데이터(문서, 지식베이스)를 임베딩하여 벡터 DB에 저장
- 사용자 질문도 임베딩하여 벡터 DB에서 유사한 문서를 검색
- 검색된 문서를 LLM에 함께 넣어 답변을 생성

즉, "비정형 데이터를 어떻게 정형 데이터처럼 검색 가능한 형태로 바꾸는가"라는 문제의식이 RAG 아키텍처를 이해하는 출발점이 된다.