

데이터 전처리 보고서

Oct 6, 2026 · @도현

1. 데이터 전처리의 개념과 목적

데이터 전처리는 수집한 원시 데이터를 분석이나 머신러닝 모델에 바로 쓸 수 있도록 정리하는 작업이다. 실제 데이터에는 빠진 값, 잘못 입력된 값, 중복된 행, 서로 다른 단위가 섞여 있는 경우가 많다.

이런 데이터를 그대로 쓰면 분석 결과가 틀어지고 모델 성능도 떨어진다. 흔히 "쓰레기가 들어가면 쓰레기가 나온다(Garbage In, Garbage Out)"고 말하는 이유다.

전처리의 목적

- **품질 향상:** 오류와 누락을 바로잡아 믿을 수 있는 데이터로 만든다.
- **형식 통일:** 날짜, 단위, 표기 방식을 맞춰 데이터를 함께 다룰 수 있게 한다.
- **모델 적합성:** 문자를 숫자로 바꾸고 값의 범위를 맞춰 모델이 학습할 수 있는 형태로 만든다.
- **효율성:** 필요 없는 데이터를 줄여 처리 속도를 높인다.

2. 데이터 유형과 데이터 구조

전처리 방법은 데이터의 유형에 따라 달라지므로, 먼저 각 변수가 어떤 유형인지 확인해야 한다.

유형	설명	예시
수치형 - 연속형	범위 안의 모든 값을 가질 수 있음	키, 몸무게, 온도
수치형 - 이산형	셀 수 있는 정수 값	방문 횟수, 자녀 수
범주형 - 명목형	순서가 없는 분류	성별, 혈액형, 지역
범주형 - 순서형	순서가 있는 분류	학점(A·B·C), 만족도
날짜·시간형	시점이나 기간을 나타냄	가입일, 주문 시각
텍스트형	자유롭게 작성된 문장	상품 리뷰, 문의 내용

데이터 구조

- **정형 데이터:** 행과 열로 이루어진 표 형태의 데이터다. 엑셀이나 데이터베이스 테이블이 대표적이며, 이 보고서는 주로 정형 데이터를 다룬다.
- **반정형 데이터:** 일정한 구조는 있지만 표 형태는 아닌 데이터다. JSON, XML 등이 있다.
- **비정형 데이터:** 정해진 구조가 없는 데이터다. 이미지, 음성, 긴 텍스트 등이 있다.

표 형태 데이터에서 한 행은 하나의 관측 대상(예: 고객 한 명)이고, 한 열은 하나의 변수(예: 나이)다.

3. 결측치 확인 및 처리

결측치는 값이 비어 있는 데이터다. 응답 누락, 입력 실수, 시스템 오류 등으로 생긴다. 대부분의 모델은 결측치가 있으면 학습할 수 없으므로 반드시 처리해야 한다.

확인 방법

- 변수별 결측치 개수와 비율을 계산한다.
- 결측치가 특정 조건(예: 특정 연령대)에 몰려 있는지 살펴본다.
- 빈칸 외에 "없음", "-", 0, 999처럼 결측을 뜻하는 값이 숨어 있는지도 확인한다.

처리 방법

방법	내용	적합한 경우
행 삭제	결측치가 있는 행을 지움	결측 행이 적고 무작위로 생긴 경우
열 삭제	결측치가 많은 변수를 지움	결측 비율이 매우 높은 경우
평균·중앙값 대체	해당 변수의 평균이나 중앙값으로 채움	수치형 변수 (이상치가 있으면 중앙값)
최빈값 대체	가장 자주 나온 값으로 채움	범주형 변수
예측 대체	다른 변수로 빈 값을 예측해 채움	변수 간 관계가 뚜렷한 경우

결측 여부 자체가 의미 있는 정보일 수도 있다. 이럴 때는 "결측 여부"를 나타내는 새 변수를 따로 만들어 두면 좋다.

4. 이상치 탐지 및 처리

이상치는 다른 값들과 동떨어진 값이다. 나이가 250살로 입력된 것처럼 명백한 오류일 수도 있고, 고액 구매 고객처럼 실제로 존재하는 드문 값일 수도 있다. 이상치는 평균을 크게 끌어당기고 모델 학습을 방해할 수 있다.

탐지 방법

- **IQR 방식**: 1사분위수(Q1)와 3사분위수(Q3)의 차이(IQR)를 구한 뒤, $Q1 - 1.5 \times IQR$ 보다 작거나 $Q3 + 1.5 \times IQR$ 보다 큰 값을 이상치로 본다.
- **Z-점수 방식**: 평균에서 표준편차의 몇 배만큼 떨어져 있는지 계산해, 보통 절댓값 3을 넘으면 이상치로 본다.
- **시각화**: 박스플롯이나 산점도로 튀는 값을 눈으로 확인한다.
- **업무 기준**: "나이는 0~120세"처럼 상식이나 업무 규칙으로 판단한다.

처리 방법

- **삭제**: 입력 오류가 분명하면 해당 값을 지우거나 결측치로 바꾼다.

- **값 제한:** 정해진 상한·하한을 넘는 값을 경계값으로 바꾼다.
- **변환:** 로그 변환 등으로 극단값의 영향을 줄인다.
- **유지:** 실제로 의미 있는 값이면 그대로 둔다.

이상치를 무조건 지우면 중요한 정보를 잃을 수 있다. 먼저 오류인지 실제 값인지를 확인하는 것이 중요하다.

5. 중복 데이터 및 불필요한 데이터 처리

같은 데이터가 여러 번 들어 있거나 분석에 쓸모없는 데이터가 섞여 있으면 결과가 한쪽으로 치우치고 처리 시간도 늘어난다.

중복 데이터

- **완전 중복:** 모든 열의 값이 같은 행이다. 하나만 남기고 삭제한다.
- **부분 중복:** 고객 ID처럼 고유해야 할 값이 겹치는 경우다. 최신 기록만 남기는 등 기준을 정해 정리한다.
- **표기 차이:** "서울", "서울시", "Seoul"처럼 같은 뜻이지만 다르게 적힌 값은 하나로 통일한다.

불필요한 데이터

- **식별용 열:** 일련번호, 이름처럼 분석에 의미가 없는 열은 제외한다.
- **값이 하나뿐인 열:** 모든 행이 같은 값이면 정보가 없으므로 제거한다.
- **비슷한 열:** 서로 거의 같은 정보를 담은 열(예: 출생연도와 나이)은 하나만 남긴다.
- **범위 밖 데이터:** 분석 대상 기간이나 지역에 해당하지 않는 행은 걸러낸다.

삭제하기 전에는 원본을 따로 보관하고, 몇 개의 행과 열이 줄었는지 기록해 둔다.

6. 범주형 데이터 인코딩

대부분의 모델은 숫자만 계산할 수 있다. 그래서 "서울", "부산" 같은 문자 값을 숫자로 바꿔야 하는데, 이 작업을 인코딩이라고 한다.

주요 방법

방법	방식	예시	적합한 경우
레이블 인코딩	범주마다 정수를 하나씩 부여	낮음→0, 보통→1, 높음→2	순서가 있는 범주
원-핫 인코딩	범주마다 열을 만들고 해당하면 1, 아니면 0	서울 → [1, 0, 0]	순서가 없고 범주 수가 적은 경우
빈도 인코딩	범주가 나온 횟수나 비율로 바꿈	서울 → 0.45	범주 수가 많은 경우

주의할 점

- 순서가 없는 범주에 레이블 인코딩을 쓰면, 모델이 "부산(1)이 서울(0)보다 크다"처럼 잘못된 관계를 배울 수 있다.
- 원-핫 인코딩은 범주 수만큼 열이 늘어나므로, 범주가 수백 개라면 다른 방법을 고려한다.
- 학습 데이터에 없던 새로운 범주가 나중에 들어올 경우를 미리 대비해 둔다.

7. 데이터 정규화와 표준화

변수마다 값의 범위가 다르면 큰 값을 가진 변수가 결과에 더 큰 영향을 준다. 예를 들어 나이(20~60)와 연봉(2,000만~1억)을 그대로 쓰면, 모델은 연봉을 훨씬 중요하게 여기게 된다. 이를 막기 위해 값의 범위를 맞춘다.

정규화 (Min-Max Scaling)

모든 값을 0과 1 사이로 바꾼다.

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

범위가 정해져 있어 이해하기 쉽지만, 이상치가 있으면 나머지 값들이 한쪽으로 몰린다.

표준화 (Z-score)

평균이 0, 표준편차가 1이 되도록 바꾼다.

$$z = \frac{x - \mu}{\sigma}$$

(μ : 평균, σ : 표준편차) 이상치의 영향을 정규화보다 덜 받으며, 많은 모델에서 기본으로 쓰인다.

언제 필요한가

- 거리를 계산하는 모델(KNN, K-평균 군집 등)에서 특히 중요하다.
- 선형 회귀, 신경망처럼 경사하강법으로 학습하는 모델도 학습이 빨라진다.
- 의사결정나무 계열 모델은 값의 크기보다 순서를 보므로 큰 영향을 받지 않는다.

변환 기준(최솟값, 평균 등)은 학습 데이터로만 계산하고, 같은 기준을 평가 데이터에 그대로 적용해야 한다.

8. 데이터 변환 및 파생변수 생성

데이터 변환

데이터의 분포나 형식을 분석에 알맞게 바꾸는 작업이다.

- **로그 변환**: 소득, 가격처럼 한쪽으로 크게 치우친 값을 고르게 만든다.
- **구간화**: 연속된 숫자를 몇 개의 구간으로 나눈다. 예: 나이 → 10대, 20대, 30대.

- **형식 변환:** 문자로 저장된 날짜나 숫자를 올바른 자료형으로 바꾼다.

파생변수 생성

기존 변수를 조합하거나 가공해 분석에 도움이 되는 새 변수를 만드는 작업이다. 모델 성능을 높이는 데 효과가 큰 단계다.

원래 변수	파생변수	활용
생년월일	나이	연령대별 분석
주문 일시	요일, 시간대, 주말 여부	구매 패턴 분석
키, 몸무게	BMI	건강 상태 판단
총 구매액, 구매 횟수	평균 구매액	고객 등급 분류
가입일, 기준일	가입 기간	이탈 가능성 예측

좋은 파생변수를 만들려면 해당 분야에 대한 이해가 필요하다. 만든 변수가 실제로 도움이 되는지는 분석 결과로 확인한다.

마치며

데이터 전처리는 분석 결과의 신뢰도를 결정하는 기초 단계다. 데이터의 유형을 먼저 파악하고, 결측치·이상치·중복을 정리한 뒤, 인코딩과 스케일 조정, 파생변수 생성으로 분석에 맞는 형태를 만든다. 모든 과정은 원본을 보존하고 처리 내용을 기록하면서 진행해야 한다.