

데이터 전처리

데이터 전처리란?

데이터 분석을 위해 수집한 데이터를 분석에 적합한 형태로 가공하는 과정
불필요한 데이터를 제거하고, 결측치나 이상치를 처리하는 과정
머신러닝에서는 모델 학습 전에 데이터를 모델이 이해할 수 있는 형태로 바꾸는 단계

필요성

데이터의 질이 좋지 않으면 분석 결과가 부정확하게 나옴
원시 데이터는 모델 학습에 적합한 형태가 아님
결측치나 이상치가 그대로 있으면 모델 성능이 떨어짐

데이터 전처리 방법

데이터마다 특성이 달라서 과정도 조금씩 다르지만 보통 아래 순서를 따름

1. 데이터 수집 (DB, 파일, API, 크롤링 등)
2. 데이터 탐색 및 이해 (데이터의 구조, 특성, 분포 등을 이해하고 잠재적인 문제 인식)
3. 결측치 처리
4. 이상치 처리
5. 데이터 스케일링 (표준화, 정규화 등을 사용)
6. 범주형 데이터 인코딩 (범주형 변수를 숫자형으로 변환)
7. 특성 선택 및 추출 (모델학습에 가장 유용한 특성 선택 또는 추출)
8. 데이터 정규화 (데이터의 분포 조정을 통해 모델의 학습 안정화)
9. 데이터 변환 (텍스트 토큰화, 이미지 전처리 등 모델이 이해하기 쉬운 형태로 변환)

결측치 처리

결측치는 값이 비어있는 데이터 (NaN 또는 빈 값으로 표시됨)

1. 삭제 (dropna)
결측치가 적거나 무작위로 생긴 경우, 분석에 별 영향 없는 변수인 경우 사용
많이 지우면 데이터 손실이 커짐
2. 평균값, 중앙값, 최빈값으로 채우기 (fillna)
평균값은 전체 평균을 유지하고 싶을 때 (예: 시험 점수)

중앙값은 이상치 영향을 줄이고 싶을 때 (예: 소득 데이터)

최빈값은 범주형 데이터일 때 (예: 성별)

3. 앞이나 뒤의 값으로 채우기 (ffill, bfill)

시계열 데이터처럼 순서대로 이어지는 데이터에서 사용

첫 번째나 마지막 값이 비어있으면 채울 값이 없어서 그대로 남음

4. 선형 보간 (interpolate)

앞뒤 값을 직선으로 이어서 중간값을 추정하는 방법

시계열, 음성, 공간 데이터처럼 일정한 추세가 있을 때 사용

애도 첫 값이 비어있으면 안 채워짐

이상치 처리

이상치는 일반적인 패턴에서 크게 벗어난 값

모델 성능을 떨어뜨릴 수 있어서 찾아서 삭제하거나 다른 값으로 대체함

찾을 때는 보통 IQR(사분위수 범위 밖의 값)이나 Z-score(평균에서 너무 멀리 떨어진 값)를 많이 씀

무조건 지우기보다는 실제로 의미 있는 값인지 확인하고 처리해야 함

데이터 스케일링

변수마다 값의 범위가 다르면 범위가 큰 변수가 모델에 더 큰 영향을 줌

그래서 범위를 비슷하게 맞춰주는 과정

모델 성능이 좋아지고 학습도 빨라짐

표준화 (Standardization)

평균 0, 표준편차 1이 되도록 변환

$z = (x - \text{평균}) / \text{표준편차}$

sklearn의 StandardScaler 사용

정규화 (Normalization, Min-Max Scaling)

값을 0~1 (또는 -1~1) 범위로 변환

$x' = (x - \text{최솟값}) / (\text{최댓값} - \text{최솟값})$

sklearn의 MinMaxScaler 사용

범주형 데이터 인코딩

모델은 문자를 직접 못 받아서 숫자로 바꿔줘야 함

레이블 인코딩

범주마다 숫자 하나씩 부여 (빨강 0, 파랑 1, 초록 2)

숫자에 크기 순서가 있는 것처럼 모델이 오해할 수 있음

원-핫 인코딩

범주 개수만큼 열을 만들고 해당하는 칸만 1, 나머지는 0

순서 문제는 없지만 범주가 많으면 열이 너무 많아짐

특성 선택 및 추출

특성 선택은 기존 특성 중에서 쓸모 있는 것만 고르는 것

특성 추출은 기존 특성을 조합해서 새로운 특성을 만드는 것 (예: PCA)

모델 복잡도를 줄이고 과적합을 막을 수 있음

데이터 변환

데이터 종류에 맞게 형태를 바꾸는 과정

텍스트는 토큰화, 이미지는 크기 조정 같은 전처리가 여기에 해당

참고

<https://dykm.tistory.com/75>https://m.blog.naver.com/mit_or_kr/223464701251