



데이터 전처리/탐색적 데이터 분석/시각화

🕒 작성일시	2026년 9월 28일 오후 5:41
☑ O/X	☐

1. 데이터 전처리의 개념과 목적

데이터 전처리는 분석이나 모델링에 적합한 형태로 데이터를 정리하고 변환하는 과정이다. 주요 목적은 다음과 같다.

- 알고리즘 호환성 충족

머신러닝 모델은 숫자만 계산할 수 있다. 글자나 사진 데이터는 읽지 못하므로, 컴퓨터가 계산할 수 있는 숫자 형태로 번역해야 한다.

- 학습 속도 및 성능 최적화

분석에 필요 없는 데이터를 버리고 핵심만 남기면 컴퓨터가 쓸데없는 계산을 하지 않아도 되기에 학습 속도가 훨씬 빨라지고 예측 성능이 높아진다.

- 정확성 확보
 - AI가 올바른 정답을 학습하도록 문제 제거

2. 데이터 유형과 구조

데이터 유형	설명	예시
정형 데이터	미리 정해진 구조에 따라 저장된 데이터	엑셀 스프레드시트, 관계형 데이터베이스 테이블
반정형 데이터	데이터 내부에 구조에 대한 설명이 함께 포함된 데이터	HTML, XML, JSON, 웹 로그, 센서 데이터
비정형 데이터	정해진 구조 없이 저장된 데이터	텍스트, 이미지, 영상, Word·PDF 문서



데이터 유형별 구조 비교

3. 결측치 확인 및 처리

개념

결측치는 데이터에 값이 비어 있는 상태를 의미한다.

1단계: 결측치 확인

```
df.isna().sum()
df.isnull().sum()
#Python
#둘은 모두 같은 코드
```

각 열에 포함된 결측치의 개수를 확인하는 코드이다.

2단계: 결측치 처리

대표적인 처리 방법은 다음과 같다.

- 결측치가 포함된 행 또는 열 삭제

```
df_clean = df.dropna()
#Python
```

빈칸이 포함된 모든 데이터를 지운다.

```
df_clean = df.dropna(subset=['나이'])
#나이 컬럼에 결측치가 있는 행만 지움
```

특정 컬럼에 빈칸이 있는 경우만 행 삭제하기

```
#컬럼 단위로 지울 때는 axis=1 을 써줌
df_clean = df.dropna(axis=1)

#특정 컬럼명 하나를 콧 집어 지울 때
df_clean = df.drop(columns=['객실번호'])
```

컬럼 자체를 삭제하기

- 평균·중앙값·최빈값으로 대체

주로 키, 몸무게, 시험 점수 같은 데이터 주로 사용

```
#점수의 빈칸을 전체 평균 점수로 채우기
mean_score = df['점수'].mean()
df['점수'] = df['점수'].fillna(mean_score)

#이상치가 많다면 평균보다 중앙값이 안전
median_score = df['점수'].median()
df['점수'] = df['점수'].fillna(median_score)
```

- 앞 또는 뒤의 값으로 대체(시계열 데이터)

```
#빈칸을 바로 앞(위)에 있는 값으로 똑같이 채우기
df['온도'] = df['온도'].ffill()

#빈칸을 바로 뒤(아래)에 있는 값으로 똑같이 채우기
df['온도'] = df['온도'].bfill()
```

4. 이상치 탐지 및 처리

1. 이상치 탐지

머신러닝 기반 방식

- **Isolation Forest:** 데이터를 무작위로 분할하여 고립시키기 쉬운 데이터(적은 분할 횟수만에 분리되는 데이터)를 이상치로 판단한다.

- **DBSCAN:** 데이터 밀도를 기반으로 클러스터링을 수행하며, 어느 클러스터에도 속하지 못하는 외곽의 데이터를 이상치(Noise)로 탐지한다.

2. 이상치 처리 방법 (Treatment)

탐지된 이상치를 무조건 삭제하는 것은 위험하다. 이상치가 발생한 원인(단순 오타입 vs 유의미한 극단값)에 따라 처리 방식을 결정한다.

- **처리 방식설명 및 적용 상황제거 (Drop):** 명백한 측정 오류이거나(예: 사람 나이가 200살), 전체 데이터 양이 충분히 많아 몇 개를 지워도 무방할 때 사용한다.
- **대체 (Imputation):** 데이터 손실을 막기 위해 다른 값으로 바꾼다. 극단값의 영향을 덜 받는 중앙값(Median)이나 비슷한 특성을 가진 데이터들의 평균으로 대체하는 것이 일반적이다.
- **스케일링/조정 (Capping):** 이상치를 완전히 삭제하지 않고 상한선과 하한선을 정해 그 안으로 값을 끌어내린다. (예: 상위 1% 값을 상위 1%의 경계값으로 변경하는 원저라이징 기법)
- **유지 (Keep):** 신용카드 사기 탐지나 공장 불량품 탐지처럼 **이상치 자체가 우리가 찾고자 하는 핵심 데이터**일 경우 그대로 둔다. 이 경우 트리(Tree) 기반 모델처럼 이상치에 강건한(Robust) 알고리즘을 사용한다.

중복 데이터 및 불필요한 데이터 제거

중복된 행이나 분석에 필요하지 않은 열을 제거한다.

범주형 데이터 인코딩

문자열로 된 범주형 데이터를 숫자 형태로 변환한다.

데이터 정규화 및 표준화

변수마다 다른 값의 범위와 단위를 일정한 기준으로 조정한다.

데이터 변환 및 파생변수 생성

기존 데이터를 분석 목적에 맞게 변환하거나 새로운 변수를 생성한다.

EDA

정의

데이터를 이해하고 패턴, 이상치, 관계 등을 발견하기 위해 다양한 시각적 및 통계적 기법을 사용하는 과정이다.

목적

- **데이터 품질 진단:** 결측치(Missing Value), 이상치(Outlier), 중복 데이터 및 데이터 입력 오류를 사전에 발견한다.
- **변수 간 관계 파악:** 변수 간의 상관관계나 예측 대상(타겟)과의 연관성을 확인하여 유의미한 패턴을 탐색한다.
- **가설 수립 및 검증:** 기존 가설을 데이터로 검증하거나, 데이터에서 유추할 수 있는 새로운 가설을 발굴한다.
- **특징 공학(Feature Engineering) 방향 설정:** 데이터 스케일링, 범주형 변수 인코딩, 파생 변수 생성 등에 대한 구조적 아이디어를 얻는다.

EDA의 4가지 주제

1. 저항성: 데이터의 손상, 오류, 특이값에 적게 영향을 받아야 한다.
2. 잔차해석: 관찰 값들이 주 경향에서 얼마나 벗어나는지 분석한다.
3. 자료의 재표현: 다른 방식의 표현한다.(로그, 제곱, 역수 변환 등)
4. 자료의 현시성: 시각적 표현

1. 저항성 (resistance)

이상치, 결측치, 입력 오류에 영향을 받지 않는 도구를 사용한다.

- EDA에서 수집 데이터의 숫자 요약 통계량으로 중앙값, 사분위수 등을 이용
- ex) 1, 2, 3, 4, 20 의 평균은 6이지만 중앙값은 3

2. 잔차해석 (residual)

관찰 값들이 주 경향에서 얼마나 벗어나는지 분석

- 경향이 벗어난 관측치가 이상치인지 영향치인지를 산점도를 이용해 판단

- 1, 2, 3, 4, 20 에서 중앙값을 중앙으로 사용하는 경우 잔차는 -2, -1, 0, 1, 17

3. 자료의 재표현 (re-expression)

- 원래 데이터에 로그, 제곱, 역수 변환 등 적용하여 다시 표현
- 분포 선형성, 분산 안정성, 분포 대칭성이 높아지도록 함수를 적용
- ex) 관찰값에 루트를 해주었더니 선형이 되었음

4. 자료의 시각적 표현 (graphical representation)

- 데이터에 숨겨진 정보를 알아보기 위하여 다양한 그래프 사용
- ex) 줄기-잎 그림, 상자 그림

일반적인 EDA 작업

1. Missing values (누락값 처리)

- 삭제: 결측치가 포함된 행을 지우거나, 결측치 비율이 과도하게 높은 열 자체를 삭제
- 대체: 평균, 중앙값, 최빈값 등 대표값으로 채워 넣거나, 알고리즘을 사용해 주변 데이터를 바탕으로 누락된 값을 예측하여 채운다.

2. Outliers (이상값 처리)

- 탐지: 주로 박스 플롯의 IQR 기법을 사용하여 상하한선을 벗어난 데이터를 찾거나, 표준점수를 통해 평균에서 표준편차의 3배 이상 떨어진 값을 식별한다.
- 처리: 단순 입력 오류라면 삭제하고, 자연적인 극단값이라면 데이터의 상/하한치로 값을 덮어쓰는 윈저라이징이나 로그 변환을 통해 값의 스케일을 축소한다.

3. data distribution (분포)

- 탐지 도구: 히스토그램, 커널 밀도 추정 그래프, 왜도 및 첨도 수치
- 조치: 소득 분포처럼 데이터가 한쪽으로 길게 꼬리를 늘어뜨린 비대칭 분포를 띠다면, 로그 변환 등을 적용해 머신러닝이 학습하기 좋은 정규분포에 가깝게 만들어준다.

4. Dropping irrelevant columns (피쳐 선택)

- 제거 대상: 모든 행이 고유값을 가지는 단순 식별자, 단일값으로만 채워져 있어 분산이 0인 변수, 수집 시점이 달라 모델에 사용할 수 없는 미래 데이터 등
- 효과: 불필요한 노이즈를 제거하여 모델의 과적합을 방지하고, 연산 속도와 메모리 효율성을 높인다.

5. Finding correlations (상관 분석)

- 타겟 변수와의 상관성: 예측하고자 하는 결과값과 강한 상관관계를 갖는 중요한 변수를 찾아내어 모델의 핵심 피처로 사용한다.
- 다중공선성 확인: 독립 변수들끼리 너무 높은 상관관계를 가지면 모델의 예측력을 떨어뜨리고 해석을 어렵게 만든다. 이를 확인하기 위해 상관 히트맵을 그리고, 겹치는 변수 중 일부는 제거하거나 주성분 분석으로 차원을 축소한다.

6. 범주형 피처(Categorical Variable) 처리 (클래스, 원핫인코딩)

텍스트나 범주로 이루어진 변수를 기계가 이해할 수 있는 수치 형태로 변환하는 과정

- 레이블 인코딩: 카테고리에 고유한 숫자를 1:1로 매핑 (학점, 등급처럼 순서나 크기에 의미가 있는 데이터에 적합)
- 원-핫 인코딩: 카테고리의 개수만큼 새로운 열을 만들고, 해당되는 열에만 1, 나머지는 0을 부여

ex) 국가명, 성별, 브랜드처럼 순서나 우열 관계가 없는 명목형 데이터에 필수적으로 사용

EDA 자동화 도구

- dtable
- pandas profiling
- sweetviz
- autoviz

데이터 과학 프로젝트의 60% 이상의 시간이 데이터 분석, 피처 선택, 피처 엔지니어링 작업에 사용

과제 EDA 및 시각화

결측치

- 표준 영문명이 비어 있는 행이 1,270임. 혼합 성분이 549건, 단일 성분이 721건

이상치

- 일부 긴 이름은 끝이 잘려 있음(10549번) ⇒이름 불완전 표시만 함.
- 한글명이 100자 이상인 성분코드: 6681, 7214, 7958, 7959, 8367, 10549, 14809, 18356, 18357, 18865, 18949, 21823, 21923, 21970, 22010, 22103, 22253, 22270, 22365, 22612, 22719, 22720, 23610

중복

- 표준 영문명은 40건이 중복돼서, 영문명을 공유하는 행이 68건임
- 구명칭은 70건이 중복됨. 구명칭 하나가 현재 이름 여러개로 갈라진 경우임.
- 구명칭 135건은 지금 다른 성분의 표준명으로 쓰이고 있어서 매핑할 때 충돌 할 수 있음.


확인 필요

- 괄호가 열리고 안 닫힌 한글명 : 성분코드 11345, 24090 ⇒수정완료
- 괄호가 제대로 안닫힌 영문명: 성분코드 22407, 22696, 23611, 23623⇒수정완료
- 코드 순서가 중간에 꼬임 (코드를 키로 쓰거나 조인하는데 문제 X)
- 24758번 한글명에 (cid:9)가 붙어 있음⇒지움

주의

- 혼합 성분은 "/"로 쪼개서 원료 단위로 분석할 수 있음. 괄호 안의 "/"는 따로 처리해야 함.

화장품 성분사전 표준화명칭목록 — 구조·분포 (정리본, n=22,021, 2026.09.30 기준)



데이터 품질 점검 요약 — 처리 상태별 (CSV↔PDF 원본 대조 반영)

