


데이터 전처리 · EDA · 시각화

데이터 분석의 첫 3단계

COW AI팀 · AI 엔지니어링 트랙 · 3주차 이론

왜 필요할까?

"Garbage in, garbage out" — 쓰레기를 넣으면 쓰레기가 나온다



앞 단계의 결과가 다음 단계의 입력이 됩니다

① 전처리 예시: 설문 데이터 정리

같은 정보인데 데이터 분석에서는 서로 다른 값으로 처리될 수 있다

BEFORE

이름	나이	학과
민수	20	컴퓨터공학
지연	스무살	컴공
수아	(빈칸)	컴퓨터공학
민수	20	컴퓨터공학

AFTER

이름	나이	학과
민수	20	컴퓨터공학
지연	20	컴퓨터공학
수아	중앙값 채움	컴퓨터공학



형식 통일 "스무살"→20, "컴공"→컴퓨터공학


중복 제거 똑같은 행 1개 삭제

결측치 삭제할지, 채울지 판단


② EDA 예시: 숫자만 보면 속는다

Anscombe의 4개 데이터셋 — 평균·분산·상관계수가 모두 같다


데이터셋 I




데이터셋 II



데이터셋 III



데이터셋 IV



4개 모두 동일

평균 $x = 9$



평균 $y \approx 7.5$

상관계수 ≈ 0.82

그런데 그림은 전부 다름!
→ 반드시 그려봐야 한다

③ 시각화 예시: 그래프로 속이기

같은 데이터, 축만 바꿨을 뿐인데 인상이 달라진다 (A·B 만족도 96점 vs 98점)



좋은 시각화 = 축·단위·기준을 정직하게

데이터를 받으면 제일 먼저 할 5가지

①~③은 전처리, ④~⑤는 EDA·시각화 — 설문 데이터 예시로

1

크기 확인

행·열이 몇 개인가?

예) 설문 응답이 200명(행) × 5문항(열)

2

빈칸 확인

어디가 얼마나 비었나?

예) 나이 칸이 30% 비어 있음 → 지울까, 채울까?

3

중복·이상값 확인

같은 행이나 엉뚱한 값은?

예) 민수가 두 번 입력됨 / 나이가 200살

4

분포 그려보기

값이 어떻게 퍼져 있나?

예) 나이 대부분 20대, 50대는 단 한 명

5

관계 그려보기

두 값이 같이 움직이나?

예) 공부 시간이 늘면 점수도 오르는가?

정리

전처리 깨끗하게 만들고

EDA 살펴보고 이해하고

시각화 정직하게 전달한다

핵심: "숫자만 믿지 말고, 그려보고, 정직하게 보여주자"