탐색적 데이터 분석(EDA)과 데이터 시각화

1. 서론

탐색적 데이터 분석(Exploratory Data Analysis, EDA)은 본격적인 분석이나 모델링에 앞서 데이터의 구조, 분포, 변수 간 관계를 살펴보는 과정이다.

EDA 는 1977 년 통계학자 존 튜키(John Tukey)가 체계화하였다. 가설을 먼저 세우고 검증하는 확증적 분석과 달리, 데이터를 관찰하면서 특징과 문제점을 찾는 데 목적이 있다.

데이터 시각화는 EDA 에서 가장 많이 쓰이는 방법이다. 본 보고서에서는 EDA 의 목적과 절차, 시각화의 역할과 주요 기법, 시각화 시 유의사항을 정리한다.

2. 탐색적 데이터 분석의 목적

- **데이터 품질 점검**: 결측치, 중복, 입력 오류, 단위 불일치를 찾는다.
- **분포 파악**: 변수별 중심 경향, 퍼짐 정도, 왜도, 이상치를 확인한다.
- **관계 탐색**: 변수 간 상관관계, 집단 간 차이, 시간에 따른 추세를 살펴본다.
- **분석 방향 설정**: 전처리 방법, 변수 변환, 사용할 통계 기법이나 모델을 정한다.

3. EDA 의 절차

EDA 의 순서는 고정되어 있지 않지만 일반적으로 다음과 같이 진행한다.

- **구조 확인**: 데이터의 행과 열 수, 변수 목록, 자료형을 확인한다.
- **기술통계**: 평균, 중앙값, 표준편차, 사분위수 등을 계산한다.
- **결측치·이상치 점검**: 발생 원인을 확인하고 제거, 대체 등 처리 방법을 정한다.
- **변수 관계 분석**: 일변량 분석에서 시작해 이변량, 다변량 분석으로 범위를 넓힌다.
- **결과 정리**: 발견한 내용을 바탕으로 가설을 세우고 후속 분석에 반영한다.

이 과정에는 주로 파이썬의 pandas 나 R 의 dplyr 를 사용한다.

4. 데이터 시각화의 역할

요약 통계량만으로는 데이터의 형태를 충분히 파악하기 어렵다. 대표적인 예가 1973 년 프랭크 앤스컴(Frank Anscombe)이 제시한 앤스컴 콰르텟이다.

앤스컴 콰르텟의 네 데이터셋은 평균, 분산, 상관계수, 회귀식이 거의 같다. 그러나 산점도로 그리면 직선형, 곡선형, 이상치 하나가 결과를 좌우하는 형태 등 서로 다른 분포를 보인다.

시각화는 이처럼 통계량에 드러나지 않는 패턴과 이상치를 확인하는 데 쓰인다. 또한 분석 결과를 다른 사람에게 전달하는 수단으로도 활용된다.

5. 분석 목적별 주요 시각화 기법

그래프는 변수의 유형과 확인하려는 내용에 따라 선택한다. 주요 기법은 다음과 같다.

분석 목적	대표 시각화	확인 내용
단일 변수 분포	히스토그램, 박스플롯, 밀도 그래프	중심, 퍼짐, 왜도, 이상치
범주형 빈도	막대그래프	범주별 빈도, 희소 범주
두 수치형 변수 관계	산점도, 회귀선	선형·비선형 경향, 군집
다변수 상관	상관 히트맵, 페어플롯	상관 구조, 다중공선성
시간에 따른 변화	선 그래프	추세, 계절성, 변화 시점
그룹 간 비교	그룹별 박스플롯, 바이올린 플롯	집단 간 분포 차이

주로 사용하는 도구는 파이썬의 Matplotlib, Seaborn, Plotly 와 R 의 ggplot2 이다. 결과를 대시보드로 공유할 때는 Tableau, Power BI 를 사용한다.

6. 시각화 시 유의사항

- **그래프 선택**: 비교는 막대그래프, 추세는 선 그래프, 관계는 산점도로 나타낸다. 항목이 많을 때는 파이 차트를 피한다.
- **축과 척도**: 막대그래프의 y 축은 0 에서 시작한다. 값의 범위가 넓으면 로그 척도를 사용한다.
- **불필요한 요소 제거**: 3D 효과나 과도한 색상, 장식은 사용하지 않는다.
- **색상**: 색각 이상자도 구분할 수 있는 팔레트를 쓰고, 색 외에 레이블이나 모양으로도 구분한다.
- **해석**: 그래프에 나타난 상관관계를 인과관계로 해석하지 않는다.

7. 결론

EDA 는 데이터 분석의 첫 단계로, 이를 생략하면 데이터 오류나 주요 패턴을 놓쳐 잘못된 결론을 내릴 수 있다.

시각화는 EDA 를 빠르게 수행하는 데 효과적이며, 분석 결과를 전달하는 데에도 활용된다. 따라서 모델링에 앞서 기술통계와 시각화를 함께 사용해 데이터를 충분히 검토해야 한다.