탐색적 데이터 분석, 시각화

탐색적 데이터 분석(EDA)이란?

Exploratory Data Analysis의 줄임말
수집한 데이터를 본격적으로 분석하기 전에 그래프나 통계로 여러 각도에서 살펴보고 이해하는 과정
데이터의 주요 특성을 요약하고 패턴이나 이상한 점을 찾아내는 단계
데이터 전처리 과정 중 데이터 탐색 및 이해 단계가 EDA에 해당함

필요성

가정을 세우기 전에 데이터부터 직접 확인할 수 있음
오류, 이상치, 결측치 같은 잠재적인 문제를 미리 발견함
처음에 생각 못 했던 패턴을 찾아서 기존 가설을 수정하거나 새 가설을 세울 수 있음
어떤 분석 방법이나 모델을 쓸지 정하는 근거가 됨
결측치를 어떻게 채울지 같은 전처리 방향도 EDA 결과를 보고 정함

EDA 과정

1. 분석 목적과 변수 확인 (어떤 변수가 있고 각각 무슨 의미인지)
2. 데이터 전체 훑어보기 (head, tail로 앞뒤 확인, 이상치나 결측치가 있는지)
3. 개별 변수 관찰 (각 변수가 예상한 범위와 분포를 갖는지, 아니면 왜 그런지 확인)
4. 변수 간의 관계 확인 (상관관계, 시각화로 개별 변수만 봐선 안 보이던 패턴 찾기)

EDA 유형

변수 개수(일변량, 다변량)와 그래프 사용 여부(그래픽, 비그래픽)로 4가지로 나눔

1. 일변량 비그래픽
   변수 하나를 통계값으로 요약
   변수 간 관계는 안 보고 데이터 자체를 설명하는 데 집중
2. 일변량 그래픽
   변수 하나를 그래프로 확인
   히스토그램은 구간별 빈도를 막대로 표현
   상자 그림(박스 플롯)은 최솟값, 1사분위수, 중앙값, 3사분위수, 최댓값을 한 번에 보여줌
   줄기 잎 그림은 값과 분포 모양을 같이 보여줌

3. 다변량 비그래픽
   변수 두 개 이상의 관계를 교차표나 통계로 확인
4. 다변량 그래픽
   변수 두 개 이상의 관계를 그래프로 확인
   산점도는 한 변수가 다른 변수에 얼마나 영향을 받는지 보여줌
   히트맵은 값을 색으로 표현 (상관관계 볼 때 많이 씀)
   그 외에 그룹 막대 그래프, 런 차트(시간에 따른 선 그래프), 버블 차트 등

변수 조합별 분석 방법

조합	요약 통계	시각화
범주형 - 범주형	교차표	모자이크 플롯
수치형 - 범주형	범주별 평균, 중앙값 등	박스 플롯
수치형 - 수치형	상관계수	산점도

변수 하나만 봐도 가설을 세우고 확인하고 수정하는 과정이 반복되는데 이게 EDA

데이터 시각화란?

차트, 그래프, 지도 같은 시각적 요소로 데이터를 표현하는 것
숫자로만 된 복잡하고 많은 데이터를 한눈에 이해할 수 있는 형태로 바꾸는 과정
데이터 안의 관계, 패턴, 추세를 쉽게 파악하고 다른 사람에게 전달하는 데 씀

EDA와 시각화의 관계

EDA에서 데이터를 이해하는 가장 대표적인 방법이 시각화
EDA 단계에서는 분석하는 사람이 데이터를 탐색하려고 씀 (패턴, 이상치 찾기)
분석이 끝난 뒤에는 결과를 다른 사람에게 설명하려고 씀 (보고서, 발표, 대시보드)

필요성

원시 데이터는 숫자만 나열돼 있어서 이해하고 활용하기 어려움
표로만 보면 안 보이던 숨은 패턴이나 추세가 그래프로 보면 바로 드러남
분석 결과를 데이터 전문가가 아닌 사람한테도 쉽게 전달할 수 있음
빠르게 전체 그림을 볼 수 있어서 의사 결정이 빨라짐

시각화의 목적

1. 아이디어 도출 (프로젝트 초반에 팀끼리 생각을 모으고 문제를 정리할 때)
2. 아이디어 설명 (전략이나 업무 흐름을 설명할 때, 예: 간트 차트)

3. 시각적 발견 (분석가가 데이터 속 패턴과 추세를 찾을 때, EDA가 여기에 해당)
4. 일상적 시각화 (성과를 꾸준히 모니터링하고 보고할 때, 예: 대시보드)

시각화의 구성 요소

스토리: 시각화로 무엇을 말하고 싶은지, 목적
데이터: 그 스토리를 뒷받침할 데이터 (정리하고 이상치 처리까지 끝낸 상태)
시각적 객체: 그걸 가장 잘 보여줄 차트나 그래프

시각화 과정

1. 목표 정의 (데이터로 답하고 싶은 질문 정하기)
2. 데이터 수집 (내부 데이터, 외부 데이터 모으기)
3. 데이터 정리 (중복 제거, 필터링, 필요한 형태로 변환)
4. 시각 자료 선택 (데이터와 전달할 내용에 맞는 차트 고르기)
5. 시각 자료 생성 (도구로 만들고 제목, 레이블, 색상 정리)

목적별 차트 선택

보여주고 싶은 것	차트
항목끼리 비교	막대 그래프, 표
전체 중 비율	원형 차트(파이 차트), 누적 막대 그래프, 트리맵
시간에 따른 변화	선 그래프, 영역 차트
값의 분포	히스토그램, 박스 플롯
두 변수의 관계	산점도, 버블 차트(변수 3개)
위치별 데이터	지도, 히트맵

표: 정보를 많이 담을 수 있지만 전체 추세 보기엔 한눈에 안 들어옴
원형 차트: 전체를 부분으로 나눠서 비율을 보여줌
선 그래프: 시간 흐름에 따른 변화를 보여줌, 예측할 때도 많이 씀
히스토그램: 구간별 데이터 개수를 막대로 보여줌, 이상치 찾기 좋음
산점도: 두 변수의 관계를 점으로 보여줌, 회귀 분석에서 많이 씀
버블 차트: 산점도에 원 크기로 변수 하나를 더 표현
히트맵: 값을 색의 진하기로 표현
트리맵: 계층 구조를 사각형 크기로 표현

데이터 종류별 시각화 유형

1. 시간 데이터: 시간에 따른 변화 (선 그래프, 타임라인)
2. 계층형 데이터: 상위 하위 관계가 있는 데이터 (트리 구조, 예: 옷 아래 셔츠, 바지, 양말)
3. 네트워크 데이터: 데이터끼리의 복잡한 관계 (산점도, 버블 차트, 워드 클라우드)
4. 다차원 데이터: 변수 여러 개를 한 그림에 (막대 그래프, 원형 차트, 누적 막대 그래프)
5. 지리 공간 데이터: 실제 위치와 관련된 데이터 (지도, 밀도 지도)

참고

https://www.ibm.com/kr-ko/think/topics/exploratory-data-analysis

https://eda-ai-lab.tistory.com/13

https://www.ibm.com/kr-ko/think/topics/data-visualization

https://aws.amazon.com/ko/what-is/data-visualization/