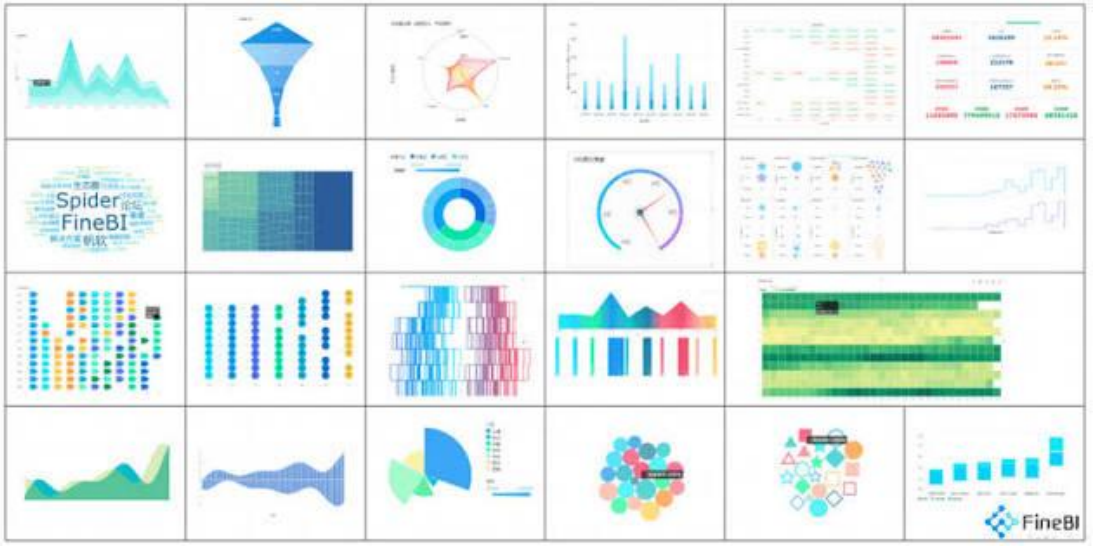
COW AI팀
데이터사이언스 2조
4주차 이론 발표

탐색적 데이터 분석(EDA) · 데이터 시각화 · 군집화 (클러스터링)

탐색적 데이터 분석이란?

탐색적 데이터 분석(EDA : Exploratory Data Analysis)의 목적은 데이터를 본격적으로 분석하거나 모델을 학습하기 전에 데이터가 어떤 특성을 가지고 있는지 이해하는 것

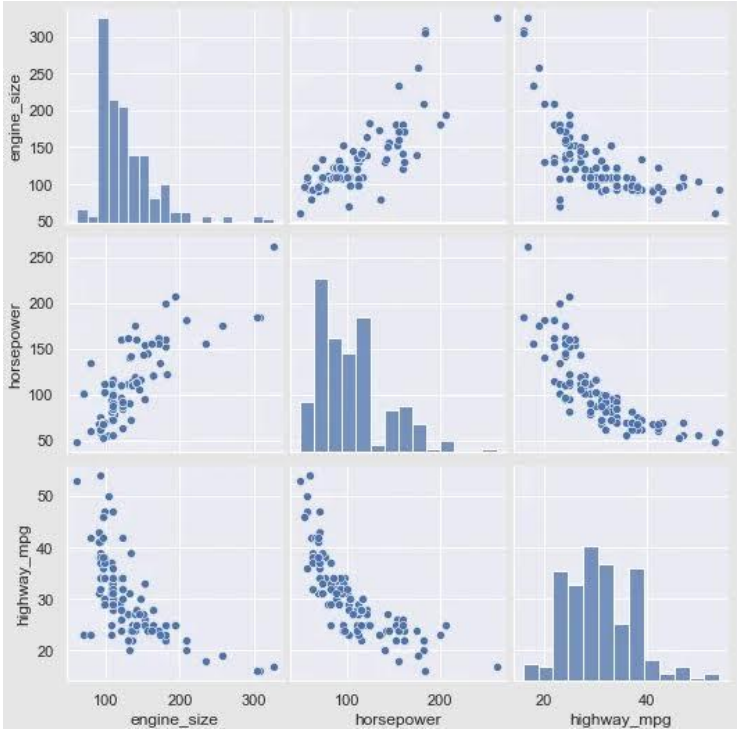
이 과정에서 새로운 패턴을 발견하거나 기존에 예상하지 못했던 문제점을 찾기도함



탐색적 데이터 분석의 종류

크게 세 가지로 분류할 수 있음.

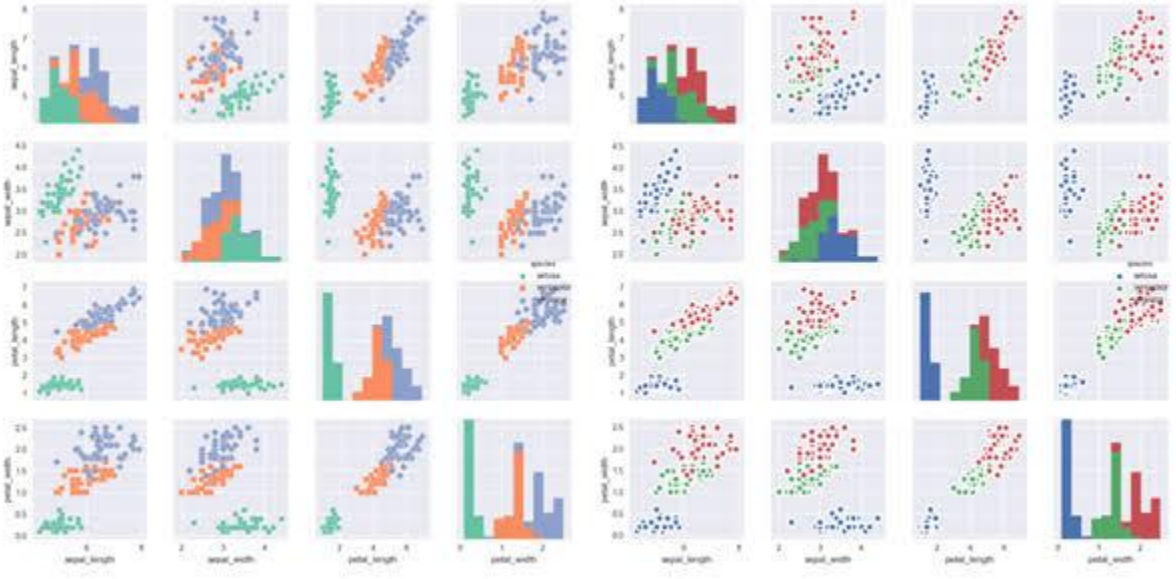
1. 단변량 분석(Univariate Analysis)
2. 이변량 분석(Bivariate Analysis)
3. 다변량 분석(Multivariate Analysis)



데이터 시각화란?

데이터 시각화란 데이터를 그래프, 차트, 도표 등으로 표현하는 방법.
복잡한 데이터를 직관적으로 이해하고
데이터에 숨어있는 패턴과
관계를 발견하는 데 도움을 줌

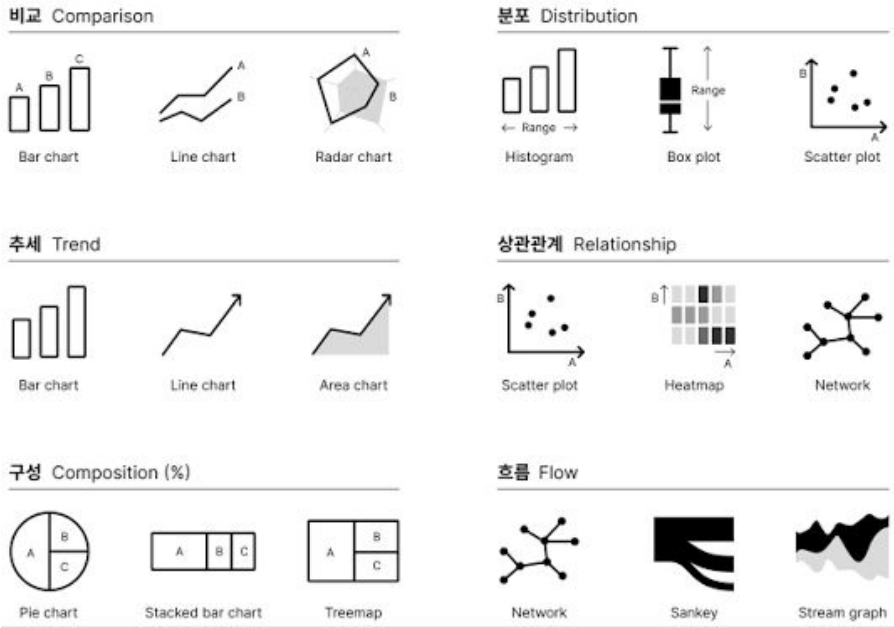
데이터 시각화 도구에는
Matplotlib, Seaborn, Ploty
등등..과 같은 도구가
유명하고 좋음



데이터 시각화의 방법과 종류

데이터를 시각화하는 방법은 다양함.
데이터 시각화의 목적에 따라 여러 방법이 있음
분포, 비교, 변화, 관계 등등...

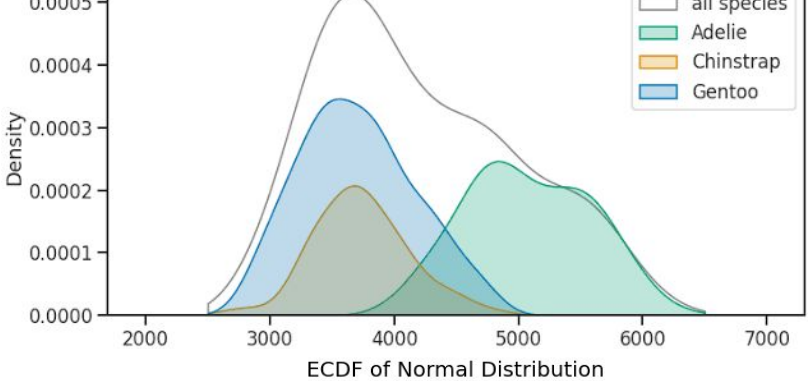
목적에 따라 적절한
시각화 방법을 사용하는 것이 중요함



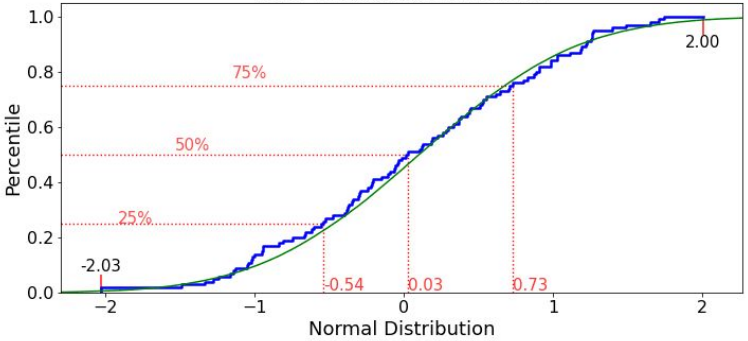
데이터의 분포 시각화 방법

데이터의 분포를 시각화 하는 방법에는 히스토그램, KDE Plot, 박스 플롯, 바이올린 플롯, ECDF Plot 등등이 있다.

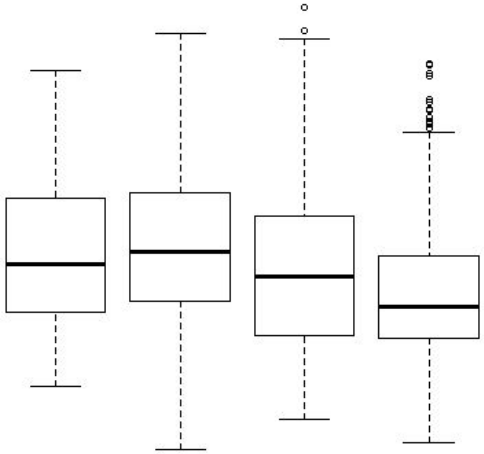
KDE Plot



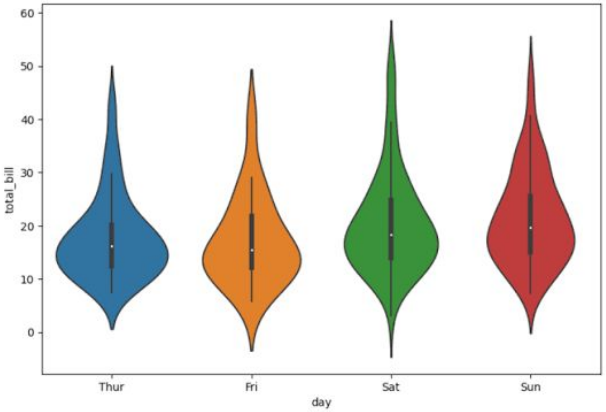
ECDF Plot



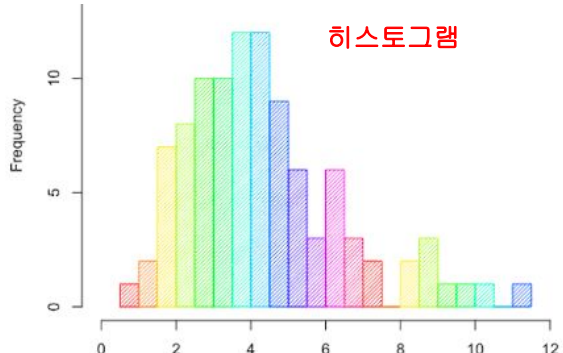
박스 플롯



바이올린 플롯



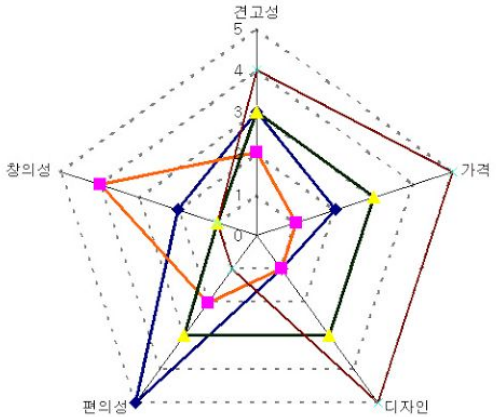
히스토그램



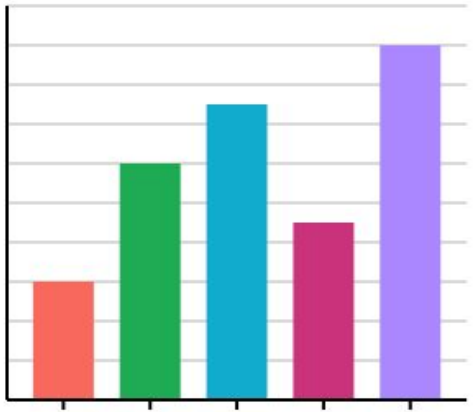
데이터 비교 및 변화 시각화 방법

데이터의 비교 및 변화 추세를 시각화 하는 방법에는 막대그래프, 누적 막대그래프, 선 그래프, 영역 그래프, 레이더 차트 등등이 있다.

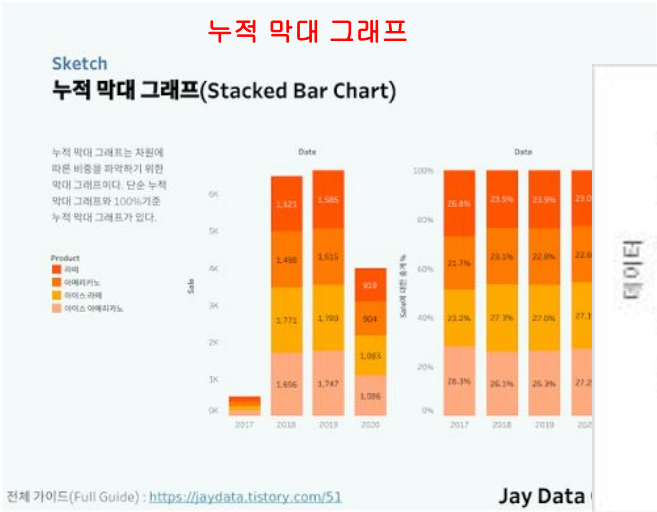
레이더 차트



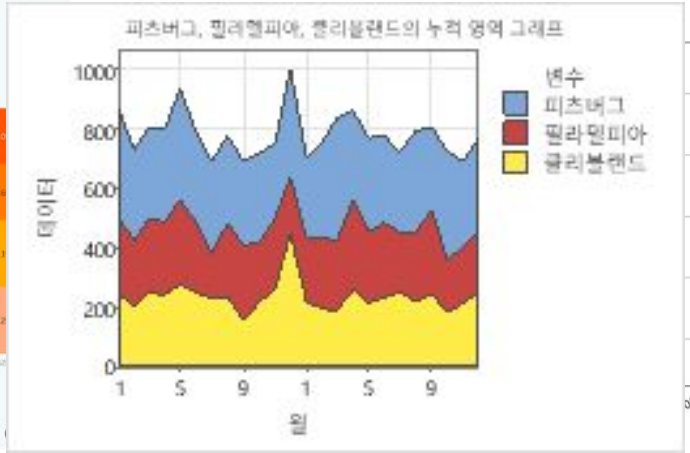
막대 그래프



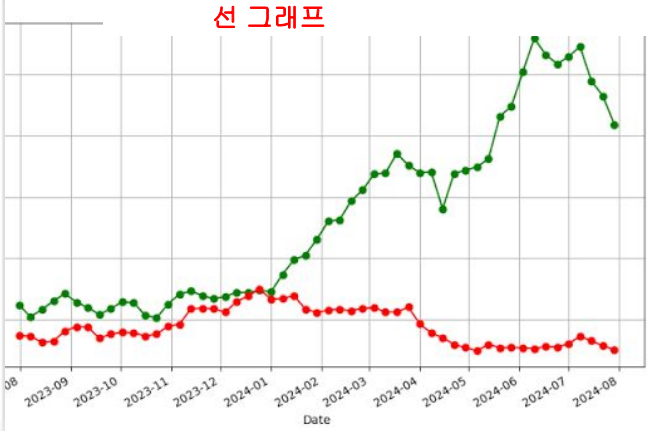
누적 막대 그래프



영역 그래프



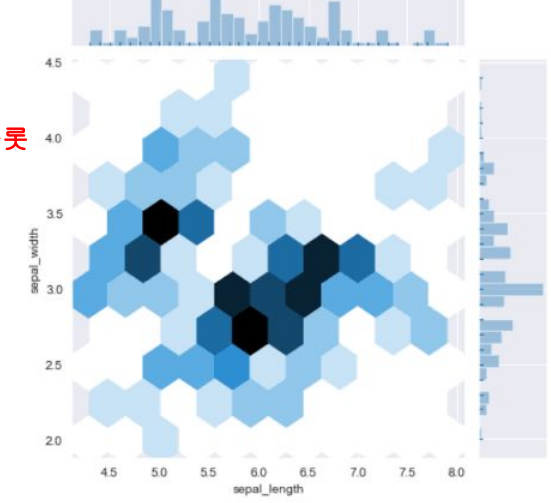
선 그래프

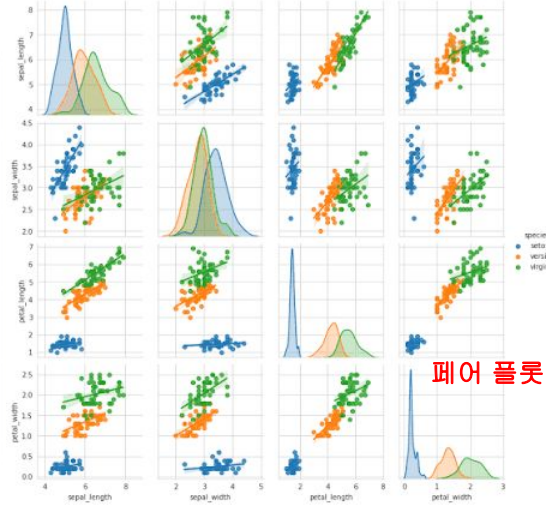


변수 간 관계 및 다변량 시각화 방법

변수 사이의 관계를 시각화하는 방법에는 산점도, 버블 차트, 히트맵, 페어 플롯, 헥스빈 플롯, 형팽좌표 그래프 등등이 있다.

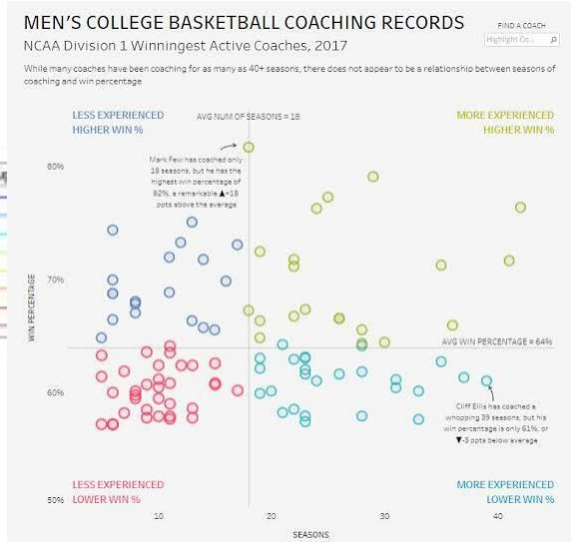
헥스빈 플롯



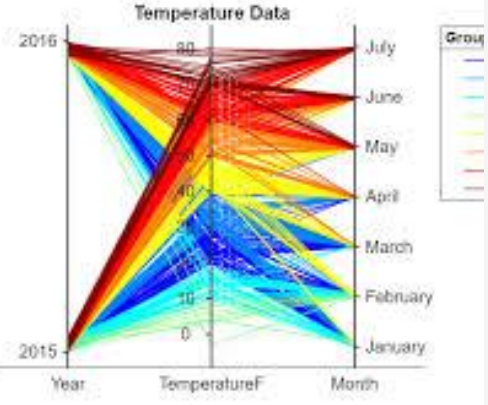


페어 플롯

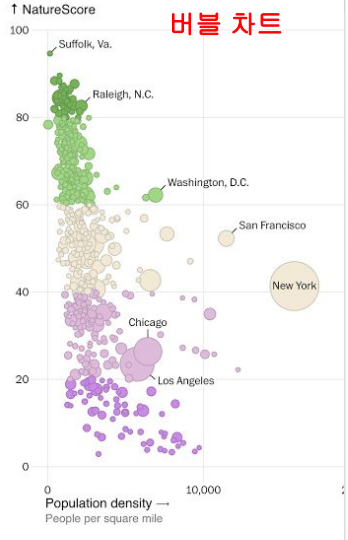
산점도



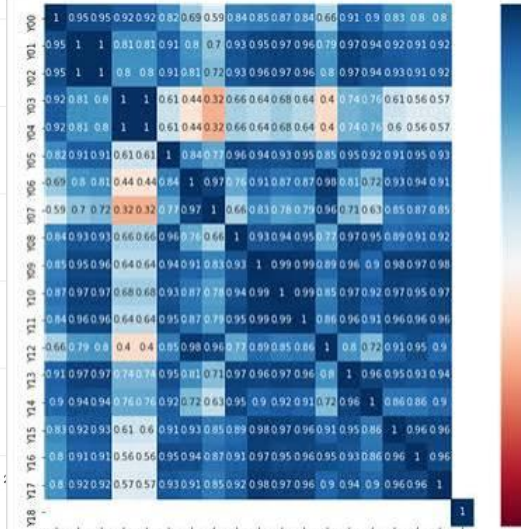
평행좌표 그래프



버블 차트



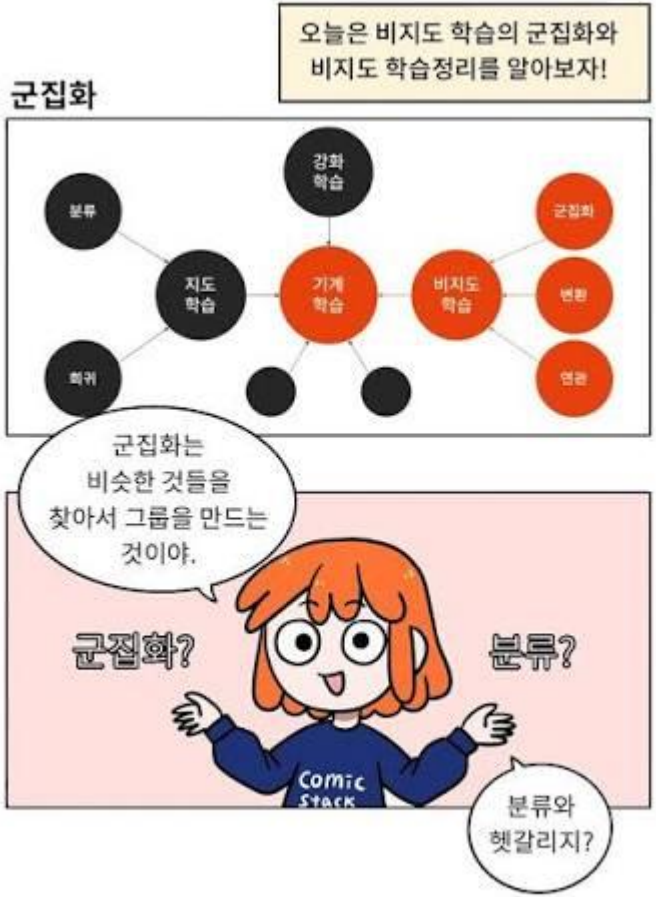
히트맵



군집화(클러스터링)란?

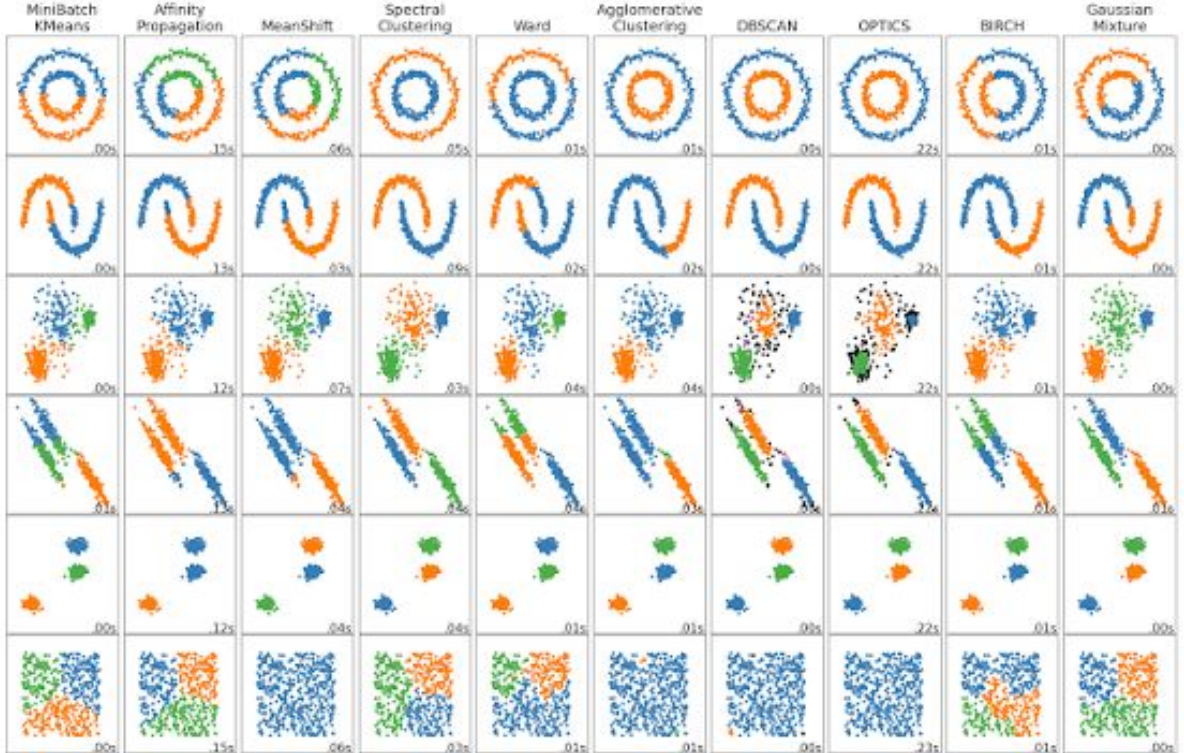
군집화란 데이터 간의 유사성을 바탕으로 비슷한 특성을 가진 데이터들을 여러 그룹(cluster)으로 묶는 비지도학습(Unsupervised Learning)기법.

군집화(Clustering)와 분류(Classification)가 헷갈릴 때는 라벨의 유무와 학습 방식을 보면 됨.



다양한 클러스터링 알고리즘들

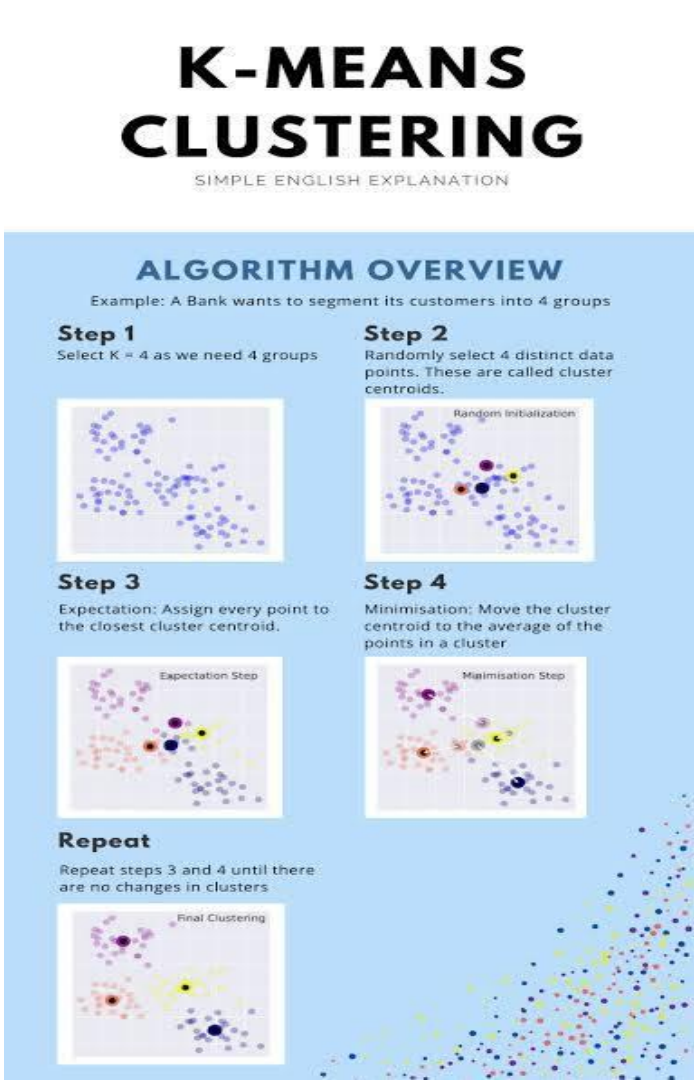
- K-Means
- AGNES, DIANA, BIRCH
- GMM
- SOM
- OPTICS, ROCK
- PAM, CLARA, CLARAS
- DBSCAN, HDBSCAN
- 기타 등등....



K-Means 알고리즘

데이터를 K개의 군집으로 분할하고 각 군집의 중심점(Centroid)과 데이터 사이의 제곱거리 합을 최소화하는 알고리즘

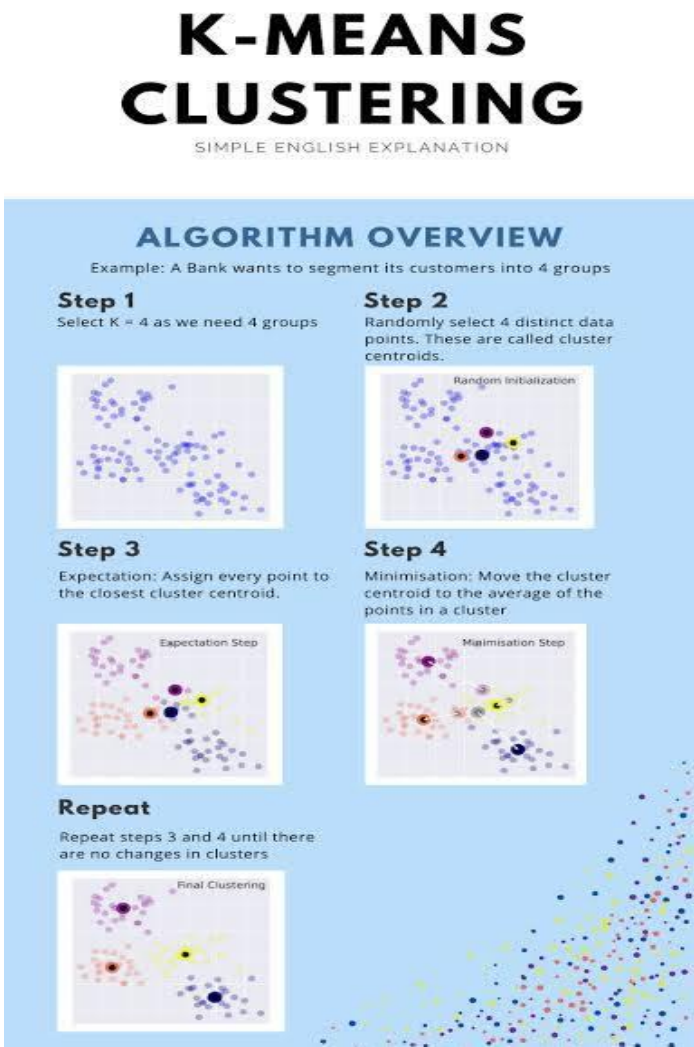
1. 초기화(Initialization) : K개의 중심점 설정
2. 할당(Assignment) : 각 데이터를 중심점에 할당
3. 갱신(Update) : 군집에 속한 데이터들의 평균으로 중심점 갱신
4. 반복(Iteration) : 군집 할당이 변하지 않거나 최대 반복 횟수만큼 반복



K-Means의 장단점과 한계

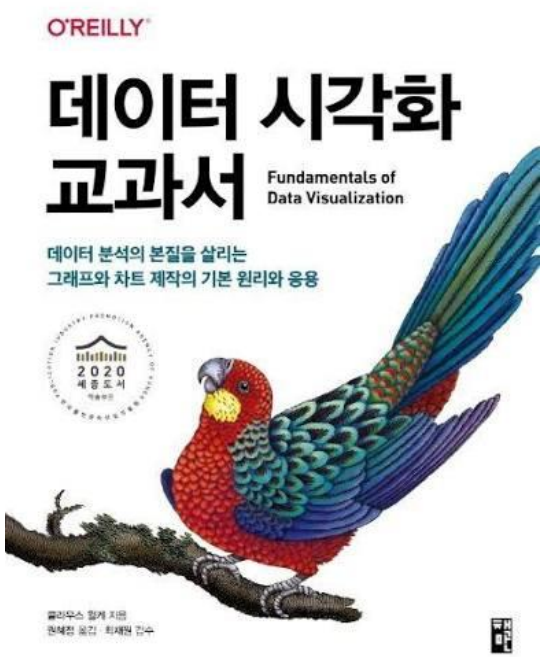
알고리즘의 구조가 단순하여 구현이 쉽고, 계산 효율이 좋고, 해석하기 쉽다는 장점이 존재

군집 개수 K개를 사전에 지정해야하고, 초기 중심점과 이상치, 스케일에 민감하고 복잡한 군집 구조를 구분하는 데 한계가 존재함

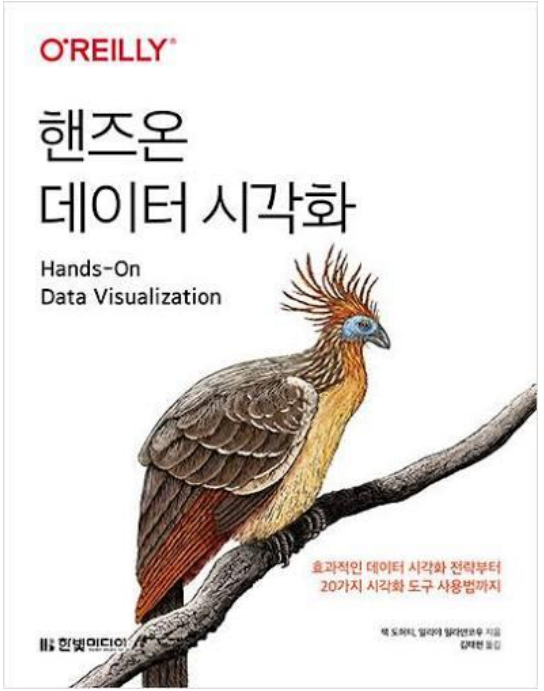


데이터 관련 좋았던 책들 공유

######강추######



추천 책
(이론 위주)



추천 책
(실습 위주)

끝

Q&A