딥러닝, 머신러닝

인공지능 / 머신러닝 / 딥러닝 관계

AI ⊃ ML ⊃ DL 순서로 포함되는 구조
인공지능(AI): 추론, 학습, 문제 해결처럼 사람의 지능이 필요한 작업을 하는 시스템을 만드는 가장 넓은 분야
머신러닝(ML): 규칙을 일일이 프로그래밍하지 않고 데이터에서 패턴을 학습해 예측하는 방법
딥러닝(DL): 여러 층의 심층신경망으로 원시 데이터에서 특성까지 직접 학습하는 머신러닝의 한 종류

머신러닝

데이터에서 패턴을 학습해서 예측하는 방법
특성은 보통 사람이 직접 골라서 가공해줘야 함

학습 방식

1. 지도 학습: 입력과 정답(라벨)을 같이 학습 (선형 회귀, KNN, 나이브 베이즈, 결정 트리)
2. 비지도 학습: 라벨 없이 데이터의 구조나 그룹을 찾음 (K-평균, 계층적 군집화, PCA)
3. 준지도 학습: 일부만 라벨이 있는 데이터를 활용
4. 강화 학습: 시행착오를 거치며 보상과 페널티로 학습

활용 예: 추천 시스템, 스팸 필터링, 설비 유지보수 예측, 고객 이탈 예측

딥러닝

여러 개의 은닉층을 가진 신경망으로 학습하는 방법
특성 추출을 네트워크가 알아서 계층적으로 학습함

주요 신경망

1. 순방향 신경망(FF): 데이터가 한 방향으로만 흐르는 가장 기본 구조
2. 순환 신경망(RNN): 시계열, 시퀀스 데이터를 다루며 이전 상태를 기억
3. LSTM: 오래된 정보도 기억하도록 개선한 RNN
4. CNN: 이미지 처리에 주로 사용
5. GAN: 생성자와 분류자가 경쟁하면서 출력 품질을 높임

활용 예: 이미지 인식, 번역과 감정 분석 같은 자연어 처리, 음성 인식, 자율주행 인식, 의료 영상 분석

머신러닝 vs 딥러닝

구분	머신러닝	딥러닝
데이터	상당한 양의 정형, 라벨 데이터	수백만 건 규모의 매우 큰 데이터
특성 추출	사람이 직접 선택하고 가공	네트워크가 자동으로 학습
하드웨어	대부분 일반 CPU로 가능	GPU, TPU 같은 고성능 병렬 연산 필요
학습 시간	초 ~ 시간 단위	시간 ~ 며칠, 몇 주 단위
해석 가능성	단순 모델은 높음 (결정 트리, 선형 회귀)	낮은 경우가 많음 (블랙박스)

구분	장점	단점
머신러닝	데이터가 적당할 때 효율적이고 빠름, 단순 모델은 해석이 쉬움	특성 추출에 전문 지식이 필요, 이미지나 음성 같은 비정형 데이터에 약함
딥러닝	비정형 데이터에 강함, 복잡한 패턴을 자동 학습, 높은 정확도	데이터와 연산 자원이 많이 필요, 학습이 오래 걸림, 결과 해석이 어려움

언제 뭘 쓰나
정형 데이터(표)이고 해석이 중요하면 머신러닝
이미지, 음성, 텍스트 같은 비정형 데이터이고 데이터가 충분하면 딥러닝
데이터가 많지 않은데 비정형 데이터를 다뤄야 하면 사전 학습 모델, 전이 학습 고려
컴퓨팅 자원이나 시간이 제한적이면 딥러닝보다 머신러닝이 현실적

CNN (합성곱 신경망)이란?

Convolutional Neural Network
이미지 같은 시각 데이터를 분석하도록 특화된 딥러닝 모델
사람의 시각 시스템에서 영감을 받았고, 모서리나 선 같은 낮은 단계의 특성부터 모양, 객체 같은 높은 단계의 특성까지 층층이 학습함
이미지뿐 아니라 격자 구조를 가진 데이터(오디오 스펙트로그램, 3D 의료 스캔 등)에도 사용 가능

CNN 구조

입력 이미지 → 합성곱 → ReLU → 풀링 → (반복) → 완전 연결 → Softmax → 클래스별 확률

계층	역할	내용
합성곱(Convolution)	특성 스캐너	필터(커널)를 이미지 전체에 슬라이드하면서 특성을 찾아 특성 맵을 만듦
활성화(ReLU)	중요도 필터	강한 신호는 남기고 약한 신호는 버림, 비선형성 도입 (f(x) = max(0, x))
풀링(Pooling)	요약 도구	특성 맵의 작은 영역(예: 2×2)에서 대표값(최댓값 등)만 뽑아 크기를 줄임
완전 연결(Fully Connected)	최종 판단	요약된 특성들을 조합해서 분류 결정
출력(Softmax)	확률 산출	각 클래스에 대한 확률을 계산

CNN 핵심 용어

필터(커널): 학습되는 작은 가중치 행렬 (예: 3×3)
특성 맵: 필터를 적용해서 나온 결과, 이미지 어디에 어떤 특성이 있는지 보여줌
가중치 공유: 같은 필터를 이미지의 여러 위치에 반복 적용함, 그래서 파라미터 수가 줄어듦
스트라이드(stride): 필터가 한 번에 이동하는 칸 수
패딩(padding): 입력 가장자리에 값을 덧대서 출력 크기를 조절
병진 불변성: 객체가 이미지 어느 위치에 있어도 인식할 수 있는 성질 (엄밀히는 합성곱의 이동 등변성과 풀링에 의한 근사적 불변성이 합쳐진 결과)

CNN 코드 예시 (PyTorch)

28×28 흑백 이미지를 10개 클래스로 분류하는 간단한 구조

```
import torch.nn as nn

model = nn.Sequential(
    nn.Conv2d(1, 16, kernel_size=3, padding=1),   # 합성곱: 필터 16개 (28x28 유지)
    nn.ReLU(),                                    # 활성화
    nn.MaxPool2d(2),                              # 2x2 최대 풀링 -> 14x14
    nn.Conv2d(16, 32, kernel_size=3, padding=1),  # 합성곱: 필터 32개
    nn.ReLU(),
    nn.MaxPool2d(2),                              # -> 7x7
    nn.Flatten(),
    nn.Linear(32 * 7 * 7, 10),                    # 완전 연결
```

```
계층
    # Softmax는 학습 시 CrossEntropyLoss에 포함되므로 생략
)
```

CNN vs 기존 신경망(완전 연결 신경망)

구분	CNN	기존 신경망
핵심 구조	합성곱, 활성화, 풀링, 완전 연결 계층	주로 완전 연결(밀집) 계층
적합한 데이터	이미지, 동영상 같은 격자형 데이터	테이블형 데이터, 평탄화된 벡터
공간 관계	보존하고 활용함	평탄화하면서 손실됨
파라미터 공유	있음 (필터 재사용)	없음 (연결마다 고유 가중치)
파라미터 수	고차원 입력에서 상대적으로 적음	고차원 입력에서 매우 많아질 수 있음

CNN 장점

특성을 자동으로 계층적으로 학습해서 수작업으로 특성을 설계할 필요 없음
공간 구조를 활용하고 병진 불변성을 가짐
파라미터 공유와 풀링 덕분에 모델 크기와 계산량이 줄고, 이미지 데이터에서 과적합이 상대적으로 덜함

CNN 활용 분야

1. 컴퓨터 비전
   이미지 분류: 이미지 전체에 라벨을 붙임 (ImageNet에서 최고 성능)
   객체 감지: 객체의 종류와 위치를 파악 (자율주행, 로봇, 보안 시스템)
   이미지 분할, 동영상 분석
2. 자연어 처리: 문장을 1차원 시퀀스로 보고 감정 분석, 번역 등에 활용
3. 의료 영상: X-ray, MRI, CT에서 종양 탐지, 골절 식별, 장기 분할
4. 신약 개발: 분자 구조로 효능과 독성을 예측, 가상 스크리닝
5. 금융: 주가, 환율 같은 시계열을 1차원 신호로 보고 추세와 이상치 탐지

CNN 한계

구조 설계가 복잡하고 하이퍼파라미터 튜닝이 필요함
대규모 학습 데이터가 필요하고 학습에 연산 자원이 많이 듦
테이블형 같은 비공간적 데이터에는 효과가 떨어짐
먼 위치 사이의 전역적 관계를 잡는 데 한계가 있음

우리 팀 주제와 연결

우리 팀은 ResNet 같은 경량 객체 인식 모델을 직접 훈련함
ResNet은 CNN 구조에 skip connection을 추가한 모델이라 CNN의 한 종류
객체 인식은 이미지에서 무엇이 어디 있는지 찾는 일이라 CNN이 가장 많이 쓰이는 분야
FGSM으로 패치를 만들 때는 모델이 미분 가능해야 입력 이미지에 대한 기울기를 구할 수 있는데, CNN이 이 조건을 만족함

참고

https://cloud.google.com/discover/deep-learning-vs-machine-learning?hl=kohttps://cloud.google.com/discover/what-are-convolutional-neural-networks?hl=ko