문서 검색 방법에는 키워드 검색, 벡터 검색, 하이브리드 겁색 이 세 방식이 있다. 이 세가지 방식은 어떤 근거로 문서가 질문과 관련이 있다고 판단하는지에서 차이가 난다.

검색방법	무엇을 기준으로 삼는가?	특징
키워드 검색	질문에 나온 단어가 문서에 등장하는지를 본다. 대표적인 방식 BM25는 단어가 얼마나 드문지, 문서 안에서 얼마나 자주 나오는지 등도 반영한다.	정확한 표현이 중요한 검색에 유용 (제품명, 오류코드, 전문용어) 같은 의미를 다른 단어로 표현한 문서는 놓칠 수 있다.
벡터 검색	질문과 문서를 각각 임베딩한 뒤, 두개의 벡터가 얼마나 비슷한지를 비교한다.	표현이 달라도 의미가 비슷한 문서를 찾을 수 있다. 결과가 임베딩 모델에 따라 달라지기 때문에, 비슷해 보이는 모델명이나 오류코드의 차이를 놓칠 수 있다.
하이브리드 검색	키워드 검색 + 벡터 검색을 모두 수행하고, 두 결과의 점수와 순위를 결합한다.	정확한 단어 일치와 의미적 유사성을 함께 반영할 수 있다.(두가지 방식의 장점이 모두 있다) 두 검색 결과를 어떤기준으로 합칠지 생각해야 한다.

ex) 사용자가 "E104오류를 어떻게 고쳐?"라는 질문을 했다고 가정했을 때,
키워드 검색은 E104라는 단어가 들어간 「E104 장애 대응 안내」를 찾는 것에 유리 하다.
벡터검색은 '고치는 방법'과 '장애 복구 절차'처럼 표현이 다른 문서도 찾을 수 있다.
하이브리드 검색은 이 모든 것을 반영할 수 있다.

키워드 검색의 점수계산법

구분	BM25	TF-IDF
기본 원리	검색어가 전체문서에서 얼마나 드문지, 몇번 나오는지,문서가 얼마나 긴지를 함께 반영하여 점수를 매긴다.	문서 안에서 자주 등장하는 단어(TF)이면서, 전체 문서에서는 드문 단어(IDF)일수록 높은 가중치를 준다.
단어 반복	같은 단어가 반복될수록 추가점수가 작아진다. 만약 문서 길이가 같다면 반복되는 횟수가 많을 수록 점수가 더 높지만 TF-IDF처럼 5배까지 올라가지는 않는다.	TF에 등장 횟수를 그대로 쓰면, 같은 단어가 1번 나올 때보다 5번 나올 때, 그 단어의 가중치가 5배가 된다.

이 둘의 차이점은 다음과 같다.

만약

문서	사과 가 나온 횟수(TF)	전체 단어 수
사과 가격	1번	2개
오늘 시장에서 본 사과 가격	1번	5개

이러한 경우가 있다고 하자.

BM25의 경우, 사과라는 단어가 나온 횟수가 같기 때문에 전체 단어수가 적은 쪽에 더 많은 점수를 준다.
하지만 TF-IDF의 경우 사과라는 단어가 나온 횟수가 같으면 전체 단어의 수를 신경쓰지 않는다.

(TF-IDF의 경우도 구현에 따라 `등장 횟수 ÷ 전체 단어 수` 로 계산하는 경우가 있는데, 이 경우에는 문서의 길이가 반영이 되는 것이다.)

벡터 검색의 유사도 계산
대표적으로 코사인 유사도 사용

하이브리드 검색

```
앞서말한 키워드 검색과 벡터 검색을 각각 한 뒤, 두 결과를 합쳐서 최종 순위를 정한다.
```

두 결과를 어떻게 합칠까?
각 검색 결과의 순위를 점수로 바꾸어 더한다.(RRF)
위쪽에 있을수록 더 높은 점수를 주고, 두 목록에 모두 나온 문서는 양쪽에서 점수를 받는다. 물론 한 목록에서만 찾은 문서도 그 목록에서 받은 점수로 최종 후보에 오를 수 있다.
