주제: 검색방법 고도화 및 검증, RAG 아키텍처 재설계

[목차]

1. RAG의 개념과 등장 배경
2. 기본(Naive) RAG의 구조와 한계
3. 청킹, 임베딩, 벡터 데이터베이스
4. 검색 방식의 종류 (키워드, 밀집, 하이브리드)
5. 쿼리 고도화와 리랭킹
6. 검색 성능 평가 지표
7. 생성 품질 평가
8. 고급 RAG 아키텍처와 재설계 시 고려사항

1. RAG의 개념과 등장 배경

LLM은 혼자서는 세 가지 문제가 있다.

- 학습 이후의 최신 정보를 모른다.
- 회사 내부 문서처럼 학습하지 않은 정보를 모른다.
- 모르는 내용도 그럴듯하게 지어내서 답한다.

RAG는 답변을 만들기 전에 **관련 문서를 먼저 검색**하고, 그 문서를 질문과 함께 LLM에 넣어 답하게 하는 방식이다. 예를 들어 '연차 규정이 어떻게 돼?'라고 물으면 인사 규정 문서에서 연차 조항을 찾아 LLM에 전달하고, LLM은 그 조항을 근거로 답한다.

<용어 설명>

- RAG (Retrieval-Augmented Generation): 검색으로 찾은 정보를 활용해 답변을 생성하는 방식이다.
- 환각 (Hallucination): LLM이 사실이 아닌 내용을 사실처럼 만들어내는 현상이다.

2. 기본(Naive) RAG의 구조와 한계

기본 RAG는 세 단계이다.

1. **인덱싱**: 문서를 조각으로 나눠 숫자로 바꿔 저장한다.
2. **검색**: 질문도 숫자로 바꿔서 가장 비슷한 조각 몇 개를 가져온다.
3. **생성**: 가져온 조각과 질문을 LLM에 넣어 답을 만든다.

한계는 다음과 같다.

- 질문이 모호하면 엉뚱한 문서를 가져온다. (예: '그거 얼마야?')
- 관련 없는 조각이 섞여도 걸러내지 못한다.
- 검색이 틀렸는지 확인하는 과정이 없어서 틀린 문서로도 그대로 답을 만든다.
- 여러 문서를 종합해야 하는 질문에 약하다.

<용어 설명>

- 인덱싱: 검색할 수 있도록 문서를 미리 정리해 저장하는 작업이다.

3. 청킹, 임베딩, 벡터 데이터베이스

- **청킹**은 긴 문서를 검색하기 좋은 크기로 나누는 작업이다. 고정 길이로 자르거나, 문단·문장 경계에서 자르거나, 내용이 바뀌는 지점에서 자를 수 있다. 경계에서 문맥이 끊기지 않도록 인접한 조각을 일부 겹치게(오버랩) 하기도 한다.
- **임베딩**은 텍스트(또는 이미지)를 숫자 묶음(벡터)으로 바꾸는 것이다. 의미가 비슷하면 벡터도 비슷하다. '환불 방법'과 '반품 절차'는 단어가 달라도 벡터가 가깝다.
- **벡터 데이터베이스는** 이 벡터를 저장하고, 질문 벡터와 가장 가까운 벡터를 빠르게 찾아주는 저장소이다.

<용어 설명>

- 청크 (Chunk): 문서를 나눈 한 조각이다.
- 벡터: 숫자를 순서대로 나열한 것이다. 예: [0.12, -0.53, 0.88, ...]
- 코사인 유사도: 두 벡터의 방향이 얼마나 비슷한지를 나타내는 값이다. 1에 가까울수록 비슷하다.
- FAISS, Chroma: 벡터 검색에 쓰는 대표적인 도구이다.

4. 검색 방식의 종류

- **키워드** 검색 (BM25): 질문의 단어가 문서에 얼마나 나오는지로 점수를 매긴다. **정확한 단어 일치**에 강하다.
- **밀집** 검색 (Dense): 임베딩 벡터의 유사도로 찾는다. 단어가 달라도 **의미가 비슷**하면 찾는다.
- **하이브리드** 검색: 두 방식의 결과를 합친다.

예시:

- 질문이 '환불 규정'인데 문서에는 '반품 정책'이라고 되어 있으면 키워드 검색은 놓치고 밀집 검색은 찾는다.
- 질문이 제품 코드 'A-1234'이면 밀집 검색은 비슷한 다른 코드를 가져올 수 있고, 키워드 검색은 정확히 찾는다.

<용어 설명>

- BM25: 단어의 출현 빈도와 희소성으로 점수를 계산하는 키워드 검색 알고리즘이다.
- RRF (Reciprocal Rank Fusion): 여러 검색 결과의 순위를 합산해 최종 순위를 만드는 방법으로, 하이브리드 검색에서 자주 쓴다.

5. 쿼리 고도화와 리랭킹

쿼리 고도화는 질문을 검색이 잘되도록 먼저 고치는 단계이다.

- 쿼리 **재작성**: 맥락을 반영해 완전한 문장으로 바꾼다.
  '그거 얼마야?' → '아이폰 15 프로의 가격은 얼마인가요?'
- 쿼리 **확장**: 동의어를 추가한다. '환불' → '환불, 반품, 취소'
- HyDE: LLM이 가상의 답변을 먼저 만들고 그 답변으로 검색한다.

리랭킹은 1차 검색으로 **후보를 넉넉히**(예: 50개) 가져온 뒤, 더 정밀한 모델로 **관련성을 다시 계산**해 **상위 몇 개**(예: 5개)만 쓰는 방법이다. 1차 검색은 빠르지만 덜 정확하고, 정밀 모델은 정확하지만 느리기 때문에 두 단계로 나눈다.

<용어 설명>

- 쿼리 (Query): 검색을 위해 입력하는 질문이나 검색어이다.
- HyDE: 가상의 문서(답변)를 만들어 그것을 임베딩해 검색하는 기법이다.
- Cross-encoder: 질문과 문서를 함께 넣어 관련성 점수를 계산하는 정밀한 모델로, 리랭킹에 자주 쓰인다.

6. 검색 성능 평가 지표

평가하려면 질문과 그 질문의 정답 문서를 미리 정해둔 **평가셋**이 필요하다.

예시: 정답 문서가 2개인 질문에서 상위 5개 중 정답이 1개 있었고, 그 정답이 3위였다고 하자.

- **Recall@K**: 정답 중 상위 K개에 들어온 비율이다. 1/2 = 0.5이다. 놓치지 않았는지를 본다.
- **Precision@K**: 상위 K개 중 정답의 비율이다. 1/5 = 0.2이다. 쓸데없는 결과가 얼마나 섞였는지를 본다.
- **MRR**: 첫 정답 순위의 역수를 여러 질문에 대해 평균낸 값이다. 3위이면 1/3이다. 정답이 얼마나 위에 있는지를 본다.
- **nDCG**: 관련 있는 문서가 위쪽에 있을수록 높게 평가하는 0~1 사이의 지표이다.

<용어 설명>

- @K: 상위 K개 결과만 본다는 뜻이다.
- Ground truth: 평가의 기준이 되는 정답 데이터이다.

7. 생성 품질 평가

검색이 좋아도 최종 답변이 나쁠 수 있어서 답변도 따로 평가한다.

- Faithfulness (충실도): 답변이 검색된 문서에 근거하는지 본다. 문서에 없는 내용을 지어냈다면 점수가 낮다.
- Answer Relevance (답변 관련성): 답변이 질문에 맞는지 본다.
- Context Precision (문맥 정밀도): 검색된 문서 중 실제로 필요한 것의 비율을 본다.
- Context Recall (문맥 재현율): 답하는 데 필요한 정보가 검색된 문서에 다 들어 있는지 본다.

사람이 일일이 채점하기 어려워서 다른 LLM이 채점하게 하는 방식을 자주 쓴다.

<용어 설명>

- Context (문맥): 검색되어 LLM에 전달된 문서 내용이다.
- RAGAS: RAG 평가를 자동으로 해주는 오픈소스 도구이다.

8. 고급 RAG 아키텍처와 재설계 시 고려사항

기본 RAG의 한계를 보완한 구조들이다.

- **Modular RAG**: 검색, 리랭킹, 쿼리 재작성 등을 독립된 모듈로 만들어 필요에 따라 조합한다.
- **Self-RAG**: 모델이 스스로 검색이 필요한지, 찾은 문서가 쓸모 있는지, 답이 문서에 근거하는지 판단한다.
- **Corrective RAG**: 검색된 문서 품질이 낮으면 쿼리를 바꿔 다시 검색하거나 웹 검색으로 보완한다.
- **Agentic RAG**: 에이전트가 계획을 세우고 어떤 자료를 몇 번 검색할지 스스로 정한다. 예를 들어 'A와 B 제품의 가격과 후기를 비교해줘'에서 A, B를 각각 검색해 결과를 합친다.

재설계할 때는 평가 지표로 약한 단계를 먼저 찾는다. 예를 들어 Recall은 낮은데 Faithfulness는 높다면 문제는 생성이 아니라 검색이므로 청킹이나 검색 방식부터 개선한다. 이때 다음 사항도 함께 고려한다.

- 지연시간: 리랭킹이나 반복 검색을 추가할수록 답변이 느려진다.
- 비용: LLM 호출 횟수와 입력 문서량이 늘수록 비용이 늘어난다.
- 환각 방지와 출처 인용: 문서에 답이 없으면 "찾을 수 없다"고 답하게 하고, 답변의 근거 문서를 표시한다.

<용어 설명>

- 에이전트: 목표를 위해 스스로 판단하고 도구를 사용하는 LLM 기반 시스템이다.
- 지연시간 (Latency): 질문을 보낸 뒤 답변을 받기까지 걸리는 시간이다.