데이터사이언스 1조

바나나를 안 배운 ResNet-50은 패치에 속을까?

적대적 패치 전이성 검증 2 · 개조 모델 3종

02

지난 결과와 남은 질문



팀이 학습시킨 바나나 패치

원본 ResNet-50이 banana라고 답한 비율

98.6%

처음 보는 사진 1,000장에 패치를 붙였을 때

구조가 다른 모델

VGG-16 · MobileNet-V2 · DenseNet-121

0~5%

바나나를 새로 배운 모델

지난주 모델 A·B·C (타겟 레이블 다름)

최대 4.6%

안 속은 이유는 타겟 레이블이 달라서일까, 모델이 바뀌어서일까?

03

바나나를 안 배운 개조 모델 3종

개조 1

가지치기 50%

몸통 가중치 중 크기가 작은 절반을 0으로 지운 모델

재학습 없음 · 타겟 레이블 그대로

개조 2

8비트 양자화

모든 가중치를 256단계 값으로 반올림한 경량화 모델

재학습 없음 · 실제 배포에 쓰는 방식

개조 3

몸통 추가 학습

타겟 레이블(fc)은 고정하고, 몸통만 바나나 없는 사진 9,469장으로 다시 학습

1에폭 · RTX 5060에서 약 1분

공통 조건 패치를 만든 같은 ResNet-50에서 출발 · 바나나 사진 0장 · 타겟 레이블(ImageNet 954번 banana) 그대로 · 패치는 다시 학습하지 않음

04

어디를 바꿨나

	몸통 (conv1 ~ layer4) 사진을 2048개 숫자로 요약	머리 (fc) · 타겟 레이블 954번 banana를 골라 답하는 곳
원본 ResNet-50	원본	원본
개조1 가지치기	가중치 50%를 0으로	원본 그대로
개조2 양자화	256단계로 반올림	256단계로 반올림
개조3 몸통 추가 학습	바나나 없는 사진으로 재학습	원본 그대로 (고정)
(지난주) 모델 A	원본 그대로 (고정)	타겟 레이블 다름 (11종 새로 학습)

회색 = 원본 그대로 · 분홍 = 숫자만 바꿈 · 빨강 = 타겟 레이블이 다름

05

모델 정상 작동 확인

패치 없는 사진 1,000장에서 원래 정답을 맞힌 비율 (1,000종 중에서 고름)

원본

82.0%

비교 기준

개조1 가지치기

75.3%

절반을 지워도 대부분 맞힘

개조2 양자화

81.9%

원본과 거의 같음

개조3 추가 학습

98.4%

같은 10종으로 학습해 높아짐*

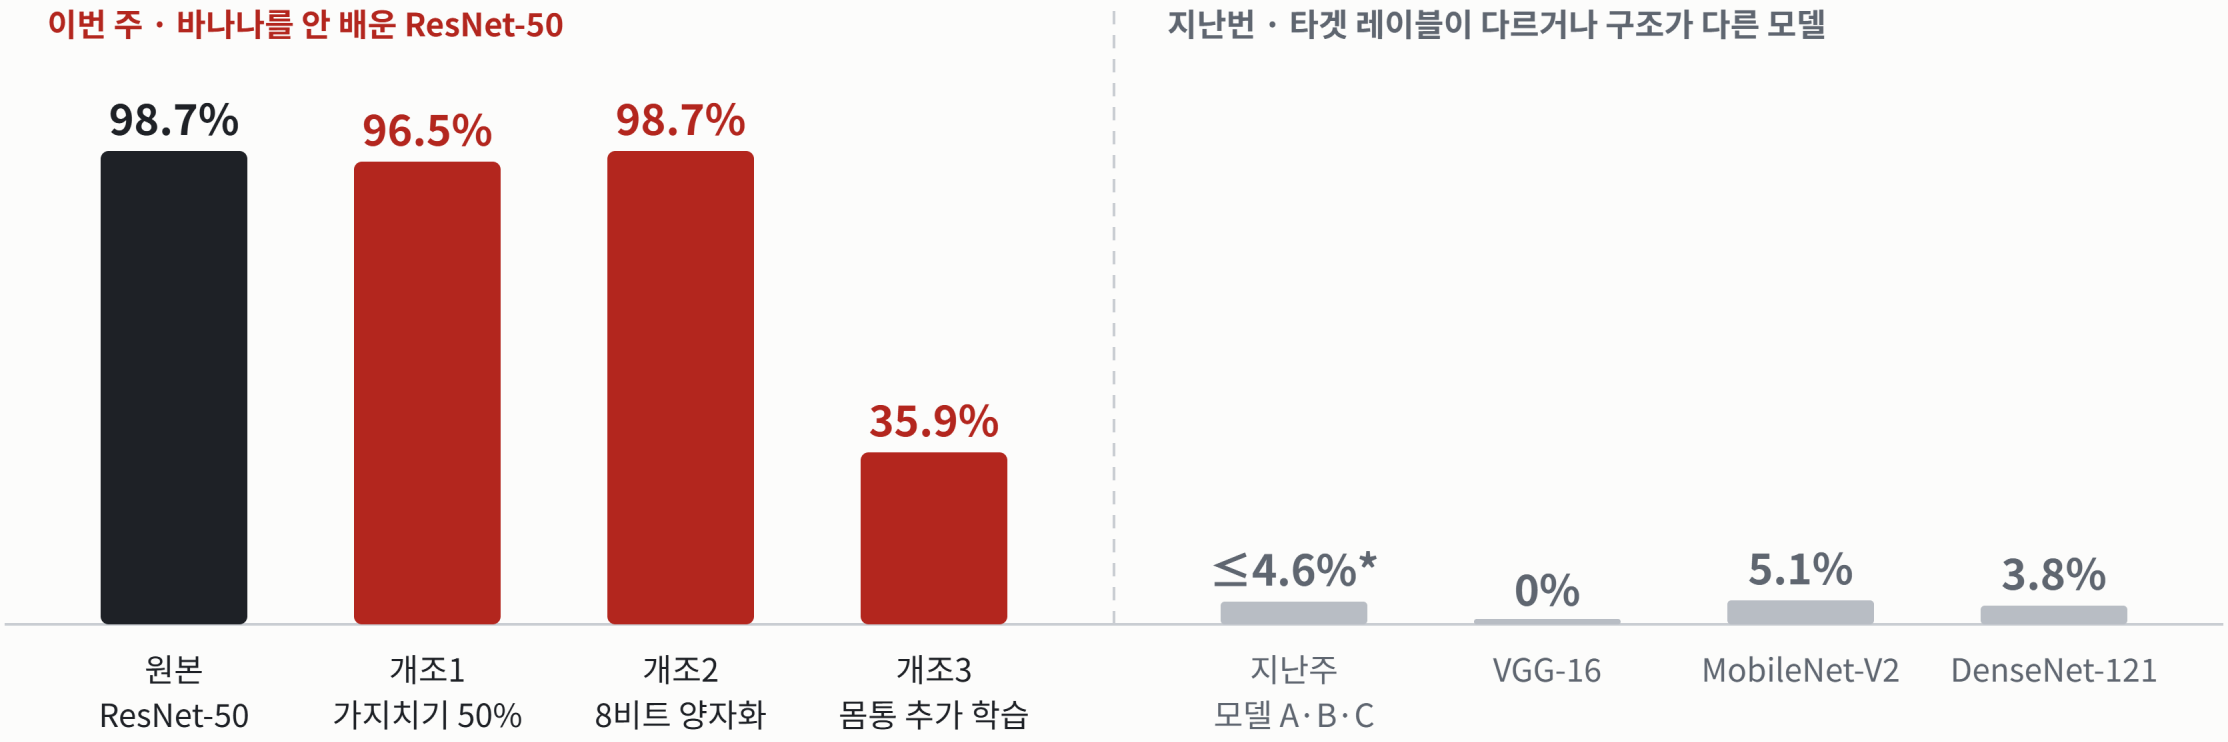
랜덤 노이즈 패치를 붙이면 모든 모델에서 banana **0%** → 아무 스티커나 붙인다고 속지 않는다

* 개조3은 평가 사진과 같은 10종으로 추가 학습해서 정답률이 오른 것 (모델이 더 좋아진 것은 아님)

06

결과 · 패치를 붙이면 banana로 답한 비율

사진 1,000장 · 패치 면적 10~20% · 회전 ±45° · 위치와 밝기 무작위

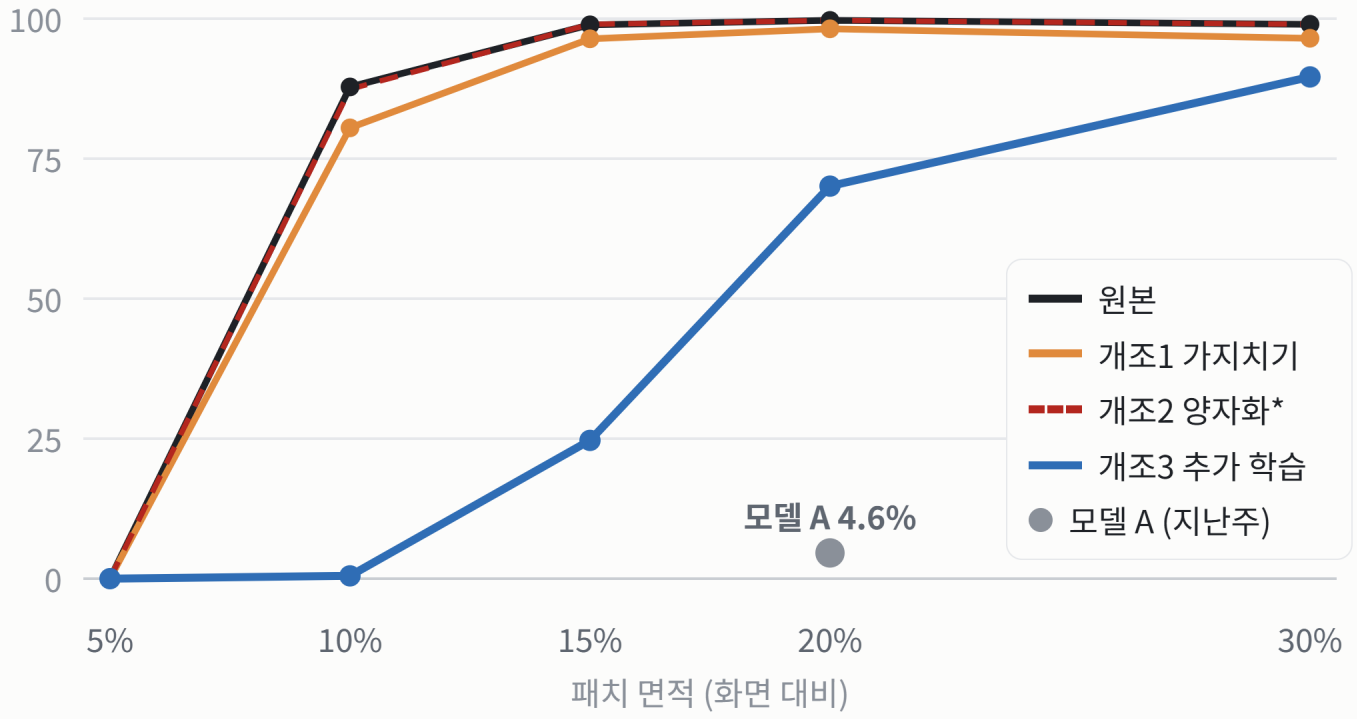


* 지난주 A·B·C는 사진 500장 · 회전 없음 조건에서 나온 최대값이라 참고용

07

면적별 결과

패치를 회전 없이 면적만 바꿔 붙였을 때 banana로 답한 비율 (%) · 사진 1,000장



면적 20%에서

개조1 · 개조2 (학습 없이 고친 모델)

98~100%

개조3 몸통 추가 학습

70.1%

지난주 모델 A (타겟 레이블 다름)

4.6%

* 개조2 선은 원본과 거의 겹침 · 모델 A 값은 지난주 발표(사진 500장) 기준

08

무엇이 패치를 막았나

	타겟 레이블 같음 (954번 banana)	타겟 레이블 다름 (새로 학습)
몸통 원본 conv1 ~ layer4 그대로	**98.7%** 원본 ResNet-50 · 개조1·2도 96.5~98.7%	**4.6%** 지난주 모델 A
몸통 재학습 다른 사진으로 다시 학습	**35.9%** 개조3 · 패치 면적 30%면 89.6%	**?** 지난주 모델 C · 같은 조건으로 재평가 필요

패치를 막은 건 타겟 레이블이 다른 것, 몸통 변화는 효과를 줄이는 정도

이번 주 값: 사진 1,000장 · 면적 10~20% · 회전 ±45° / 모델 A: 지난주 발표의 최대값 (조건이 달라 참고용)

09

결론

1

가볍게 고친 모델엔 그대로 통한다

가지치기 96.5% · 양자화 98.7%. 모델을 경량화해서 배포해도 패치를 막지 못한다

2

몸통을 재학습하면 약해진다

개조3은 35.9%. 그래도 패치를 키우면 70~90%까지 다시 통한다

3

타겟 레이블이 다르면 안 통한다

몸통이 원본과 같은 모델 A도 4.6%. 패치는 954번 banana 레이블만 노린 무늬다

다음 단계 지난주 A·B·C를 같은 조건으로 재평가 · 여러 번 반복 실행 · 여러 모델을 함께 속이는 앙상블 패치로 전이성 높이기