모델 학습 및 성능평가

이론은 학습 및 어떤 성능 평가 방법이 있는지

모델 학습이란?

모델이 실제 사용 사례와 비슷한 샘플 데이터로 성능을 높이도록 가르치는 과정
머신러닝에서는 가중치와 편향 같은 매개변수를 조정해서 더 정확한 출력을 얻는 것
학습이 끝난 매개변수 값이 모델의 지식이 됨

학습 목표

손실 함수를 최소화하는 것
손실이 정해진 임계값 아래로 내려가면 학습된 상태로 봄
강화 학습은 반대로 보상 함수를 최대화함

학습 과정

1. 모델 선택
   문제 유형, 데이터 종류, 정확도와 속도 중 뭐가 우선인지, 예산과 하드웨어(GPU 등)를 고려
2. 데이터 수집
   딥러닝은 수천 개 이상의 예제가 필요할 수 있음
   공개 데이터셋이나 합성 데이터를 쓰기도 함
3. 데이터 준비
   노이즈 제거, 값 정규화, 형식 표준화
   지도 학습은 레이블링이 필요하고 시간과 비용이 많이 듦
4. 하이퍼파라미터 선택
   학습 과정 바깥에서 사람이 정하는 값 (초기 매개변수 설정 포함)
5. 학습 데이터로 예측
   데이터를 배치 단위로 모델에 넣음, 배치 크기도 중요한 하이퍼파라미터
6. 손실 계산
   손실 함수로 예측과 정답의 차이를 측정
   딥러닝에서는 역전파로 각 노드가 손실에 기여한 정도를 계산
7. 매개변수 최적화
   경사 하강법 계열이 주로 쓰임

모델에 따라 이차 계획법, 최소 제곱법 등을 쓰기도 함
강화 학습은 PPO, DPO, A2C 같은 방법을 사용

8. 모델 평가
   5~7단계를 손실이 충분히 낮아질 때까지 반복한 뒤 평가

하이퍼파라미터

학습률, 배치 크기, 손실 함수(와 정규화 조건), 최적화 알고리즘, 초기화 방식 등
적절한 값을 찾으려면 하이퍼파라미터 튜닝이라는 시행착오 과정이 필요
비지도 학습(클러스터링의 k 값 등)도 수동 실험으로 튜닝하는 경우가 많음

학습 방식 분류

지도 학습: 정답(실측 정보)과 비교하며 학습, 분류와 회귀에 사용
비지도 학습: 정답 없이 패턴을 찾음, 클러스터링, 연관 규칙, 차원 축소
강화 학습: 상태, 행동, 보상으로 이루어진 환경에서 시행착오로 학습

과적합

모델이 학습 데이터를 거의 외워서 새로운 데이터에는 일반화하지 못하는 상태
학습 데이터에서 성능이 좋다고 해서 실제로 쓸 준비가 된 건 아님
학습 데이터 성능은 좋은데 검증 데이터 성능이 크게 떨어지면 과적합
학습 데이터와 검증 데이터 성능이 거의 비슷해야 좋은 모델

데이터 분할과 검증

학습 데이터 일부를 따로 떼어두고 교차 검증을 하는 방식이 일반적
모델이 본 적 없는 데이터로 테스트해서 학습이 제대로 됐는지 확인

모델 성능 평가란?

실제값과 모델의 예측값을 비교해서 차이(오차)를 구하는 것
오차가 0이면 예측이 완벽한 것, 현실에서는 100% 일치하기 어려워서 허용할 오차 수준을 정함
평가 목적은 과적합을 막고 최적의 모델을 찾는 것
정답이 있어야 평가할 수 있어서 지도학습에서만 사용
모델링 목적이나 목표 변수 유형에 따라 쓰는 지표가 다름

회귀 모델 평가 지표

오차 지표라서 값이 작을수록 성능이 좋음

지표	설명
MSE (평균 제곱 오차)	실제값과 예측값 차이를 제곱해서 평균
RMSE (평균 제곱근 오차)	MSE에 제곱근을 씌움, 제곱 때문에 커진 값을 실제 오차 규모에 가깝게 맞춤
MAE (평균 절대 오차)	차이의 절댓값을 평균
MAPE (평균 절대 비율 오차)	오차를 비율로 표현, MSE와 RMSE의 단점을 보완

분류 모델 평가 지표

여러 분류 모델 중 어떤 게 나은지 고를 때 사용
실제값과 예측값이 비슷한지만 봐서는 판단하기 어려워서 아래 지표들을 씀

혼동 행렬 (Confusion Matrix)
모델이 두 클래스를 얼마나 헷갈리는지 보여주는 표
오류가 얼마나 많은지뿐 아니라 어떤 유형의 오류인지도 알 수 있음

	예측 negative	예측 positive
실제 negative	TN	FP
실제 positive	FN	TP

파이썬 sklearn 기준 배치이고, R이나 교재에 따라 행과 열이 반대일 수 있음

용어
T/F: 예측이 정답이면 T, 오답이면 F
P/N: 모델이 positive 또는 negative라고 예측한 것
TP: positive로 예측했고 실제도 positive
TN: negative로 예측했고 실제도 negative
FP: positive로 예측했는데 실제는 negative
FN: negative로 예측했는데 실제는 positive

주요 지표

지표	공식	의미	중요한 경우
정확도 (Accuracy)	(TP+TN) / (TP+TN+FP+FN)	전체 중 맞게 예측한 비율	클래스 비율이 균형일 때
정밀도 (Precision)	TP / (TP+FP)	positive로 예측한 것 중 실제 positive 비율	음성을 양성으로 잘못 판단하면 안 될 때 (FP 감소)
재현율 (Recall, 민감도)	TP / (TP+FN)	실제 positive 중 positive로 찾아낸 비율	양성을 놓치면 안 될 때 (FN 감소)

지표	공식	의미	중요한 경우
F1 score	2 × Precision × Recall / (Precision + Recall)	정밀도와 재현율의 조화평균	두 지표를 균형 있게 볼 때

네 지표 모두 0~1 사이 값이고 1에 가까울수록 좋음

정확도의 한계
데이터가 불균형하면(예: positive:negative = 9:1) 정확도만으로는 제대로 분류했는지 알 수 없음
그래서 재현율과 정밀도를 같이 봄

정밀도와 재현율
둘 다 positive 예측 성능에 초점을 두고 서로 보완하는 관계
재현율이 중요한 경우: 실제 양성을 음성으로 놓치면 피해가 큰 경우
정밀도가 중요한 경우: 실제 음성을 양성으로 잘못 판단하면 문제가 큰 경우
한쪽을 높이면 다른 쪽이 떨어지기 쉬운 트레이드오프 관계
F1은 둘 중 한쪽으로 치우치지 않고 둘 다 높을 때 큰 값이 나옴

기타 지표

지표	공식	의미
오분류율 (Error Rate)	(FP+FN) / (TP+TN+FP+FN)	전체 중 잘못 맞춘 비율
특이도 (Specificity, TNR)	TN / (TN+FP)	실제 negative 중 negative로 맞게 예측한 비율
위양성률 (Fall Out, FPR)	FP / (FP+TN) = 1 - 특이도	실제 negative 중 positive로 잘못 예측한 비율

에포크(epoch): 전체 학습 데이터를 한 번 다 학습한 횟수, 배치는 한 번에 모델에 넣는 데이터 묶음
과소적합: 학습 데이터에서도 성능이 낮은 상태 (모델이 너무 단순하거나 학습이 부족할 때)
학습/검증/테스트 분할: 학습 데이터로 학습, 검증 데이터로 하이퍼파라미터 튜닝과 과적합 확인, 테스트 데이터는 마지막에 최종 성능 확인용으로만 사용
k-겹 교차 검증: 데이터를 k등분하고 한 조각씩 돌아가며 검증용으로 쓰면서 k번 학습, 평가한 뒤 평균을 냄
과적합 대응: 데이터 늘리기, 정규화(규제), 조기 종료, 드롭아웃
ROC-AUC: 임계값을 바꿔가며 재현율(TPR)을 세로축, 위양성률(FPR)을 가로축으로 그린 곡선이 ROC, 그 아래 면적이 AUC, 1에 가까울수록 좋고 0.5면 무작위 수준

참고

https://www.ibm.com/kr-ko/think/topics/model-traininghttps://bigdaheta.tistory.com/53https://white-joy.tistory.com/9